

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



SOICT

**BÁO CÁO BÀI TẬP LỚN:
DỰ BÁO MÔI TRƯỜNG NUÔI TRỒNG
CHO CÁ GIÒ VÀ HÀU**

HỌC PHẦN: NHẬP MÔN KHOA HỌC DỮ LIỆU - IT4930

Giảng viên hướng dẫn:	PSG.TS Phạm Văn Hải
Nhóm sinh viên thực hiện:	Bùi Lê Hùng - 20224994 Bùi Lê Huy - 20225005 Nguyễn Khánh Huyền - 20225016 Nguyễn Đình Hiếu - 20224847 Nguyễn Đạt Trọng - 20225103
Nhóm:	8
Mã lớp:	162301

Hà Nội, ngày 7 tháng 1 năm 2026

Mục lục

1	Giới thiệu	3
1.1	Lí do chọn đề tài	3
1.2	Nội dung thực hiện	3
2	Xử lý dữ liệu	5
2.1	Bộ tiêu chí cho cá giò và hào	5
2.2	HK Dataset	6
2.2.1	Cấu trúc bộ dữ liệu và nguồn dữ liệu	6
2.2.2	Chuẩn hóa và làm sạch dữ liệu	7
2.2.3	Tổng hợp dữ liệu theo thời gian	7
2.2.4	Chuẩn hóa lược đồ thuộc tính	7
2.2.5	Bổ sung dữ liệu tổng hợp	8
2.2.6	Tạo bộ dữ liệu cuối cùng	8
2.3	Bộ dữ liệu môi trường biển Việt Nam	8
2.3.1	Cấu trúc bộ dữ liệu và nguồn dữ liệu	8
2.3.2	Gộp và sắp xếp dữ liệu	9
2.3.3	Xử lý giá trị left-censored	9
2.3.4	Chuẩn hóa lược đồ thuộc tính	9
2.3.5	Kết hợp tọa độ địa lý	10
2.3.6	Bổ sung dữ liệu tổng hợp	10
2.3.7	Tạo bộ dữ liệu cuối cùng	11
3	Xây dựng mô hình dự báo chất lượng nước	12
3.1	Cơ sở lý thuyết và Phương pháp tiếp cận	12
3.1.1	Thuật toán Extreme Gradient Boosting (XGBoost)	12
3.1.2	Chiến lược Học chuyển giao	14
3.2	Thiết kế đặc trưng	15
3.2.1	Lựa chọn biến đầu vào	15
3.2.2	Kỹ thuật tạo biến trễ (Lag Features)	17
3.3	Huấn luyện mô hình cơ sở (Base Model - HK Dataset)	18
3.3.1	Thiết lập bài toán Multi-output Regression	18
3.3.2	Cấu hình tham số tối ưu	20
3.4	Tinh chỉnh mô hình trên dữ liệu Việt Nam	22
3.4.1	Cơ chế Kế thừa tham số mô hình (Parameter Inheritance)	22
3.4.2	Điều chỉnh tốc độ học	23
3.5	Đánh giá hiệu năng	24
3.5.1	Phương pháp đánh giá thực nghiệm	24
3.5.2	Đánh giá kết quả so sánh định lượng	25

4	Xây dựng bộ chỉ số phù hợp sinh học và bản đồ vùng nuôi	28
4.1	Công thức tính mức độ phù hợp sinh học (HSI)	28
4.1.1	Chỉ số phù hợp sinh cảnh (Habitat Suitability Index – HSI)	28
4.1.2	Nguyên tắc xây dựng chỉ số HSI	28
4.1.3	Hàm đánh giá mức độ phù hợp cho từng biến	28
4.1.4	Tính toán chỉ số HSI tổng hợp	29
4.1.5	Phân loại mức độ phù hợp sinh cảnh	29
4.2	Xác định phạm vi áp dụng của kết quả dự đoán	29
4.2.1	Nguyên tắc xác định bán kính ảnh hưởng	29
4.2.2	Phân tích suy giảm tương đồng sinh thái theo khoảng cách	30
4.2.3	Ngưỡng xác định mất tương đồng sinh thái	30
4.2.4	Xác định bán kính ảnh hưởng R	31
4.2.5	Ví dụ minh họa xác định bán kính ảnh hưởng không gian	31
4.3	Thiết kế dashboard và bản đồ dự báo vùng nuôi trồng	32
4.3.1	Kiến trúc tổng thể của hệ thống Dashboard	32
4.3.2	Các thành phần giao diện người dùng	33
4.3.3	Cơ chế tính toán và hiển thị kết quả	34
4.3.4	Tối ưu hóa hiệu năng và trải nghiệm người dùng	35
4.3.5	Ý nghĩa thực tiễn và khả năng ứng dụng	36
5	Kết luận	37
5.1	Kết quả thu được	37
5.2	Đánh giá kết quả và hướng phát triển	38
6	Tài liệu tham khảo	39

1 Giới thiệu

1.1 Lí do chọn đề tài

Vùng biển ven bờ Việt Nam là khu vực có điều kiện tự nhiên thuận lợi cho nuôi trồng và khai thác nhiều loài thủy sản có giá trị kinh tế cao, trong đó tiêu biểu là cá giò và hào. Các loài này không chỉ đóng vai trò quan trọng trong phát triển kinh tế biển và sinh kế của người dân ven biển, mà còn góp phần thúc đẩy ngành nuôi trồng thủy sản theo hướng hàng hóa và xuất khẩu. Tuy nhiên, hiệu quả và tính bền vững của hoạt động nuôi trồng thủy sản phụ thuộc chặt chẽ vào chất lượng môi trường nước, vốn chịu tác động đồng thời của nhiều yếu tố vật lý, hóa học và sinh học.

Các thông số môi trường như oxy hòa tan (DO), pH, độ mặn, nhiệt độ, nồng độ các chất dinh dưỡng và chất ô nhiễm (NH, HS, TSS, BOD, kim loại nặng, v.v.) có ảnh hưởng trực tiếp đến quá trình sinh trưởng, sức khỏe, khả năng sinh sản và tỷ lệ sống của cá giò và hào. Trong bối cảnh biến đổi khí hậu, nước biển dâng, thay đổi chế độ mưa – dòng chảy, cùng với sự gia tăng của các hoạt động xả thải công nghiệp, nông nghiệp và đô thị ven biển, các điều kiện môi trường biển ngày càng biến động phức tạp và khó dự đoán. Các phương pháp đánh giá truyền thống dựa trên quan trắc đơn lẻ hoặc phân tích thống kê đơn giản thường không đủ khả năng phản ánh đầy đủ tính động, tính chu kỳ và mối quan hệ phi tuyến giữa các yếu tố môi trường theo không gian và thời gian. Do đó, việc ứng dụng các phương pháp học máy và phân tích dữ liệu hiện đại vào bài toán đánh giá và dự báo chất lượng môi trường nước là cần thiết và có ý nghĩa thực tiễn cao. Thông qua việc khai thác dữ liệu quan trắc lịch sử, các mô hình học máy có thể hỗ trợ dự báo sớm rủi ro môi trường, xác định vùng nuôi có mức độ phù hợp cao, đồng thời cung cấp cơ sở khoa học cho việc ra quyết định trong quản lý, quy hoạch và phát triển nuôi trồng thủy sản theo hướng bền vững.

1.2 Nội dung thực hiện

Trong khuôn khổ dự án, nhóm tập trung xây dựng một quy trình phân tích và dự báo chất lượng môi trường nước nhằm phục vụ đánh giá mức độ phù hợp sinh cảnh (Habitat Suitability Index – HSI) cho nuôi trồng thủy sản, cụ thể là đối với hai đối tượng nghiên cứu chính: hào và cá giò. Quy trình được thiết kế theo hướng tổng hợp, kết hợp giữa phân tích dữ liệu môi trường, mô hình học máy và đánh giá sinh thái.

Trước hết, dữ liệu quan trắc môi trường nước theo quý tại các trạm ven biển được thu thập và tiến hành tiền xử lý. Các bước tiền xử lý bao gồm chuẩn hóa định dạng thời gian, làm sạch dữ liệu, xử lý các giá trị bị thiếu thông qua nội suy và thống kê đặc trưng, loại bỏ hoặc làm giảm ảnh hưởng của các giá trị ngoại lai, cũng như xây dựng các đặc trưng độ trễ (lag features). Việc sử dụng các đặc trưng độ trễ cho phép mô hình phản ánh được tính chất chuỗi thời gian, xu hướng và chu kỳ mùa vụ của các yếu tố môi trường tại từng trạm quan trắc.

Tên cơ sở dữ liệu đã được xử lý, nhóm xây dựng và huấn luyện các mô hình học máy dựa trên thuật toán XGBoost để dự báo các biến môi trường theo quý. Các mô hình được chia thành hai nhóm chính: nhóm mô hình dự báo các kim loại nặng (như CN, As, Cd, Pb, Cu, Hg, Zn, Total Cr) và nhóm mô hình

dự báo các biến môi trường không phải kim loại (như DO, pH, nhiệt độ, độ mặn, NH, BOD, TSS, v.v.). Phương pháp dự báo cuốn chiếu (rolling forecast) được áp dụng nhằm dự báo nhiều quý trong tương lai cho từng trạm, trong đó kết quả dự báo của các quý trước được sử dụng làm đầu vào cho các bước dự báo tiếp theo.

Kết quả dự báo các yếu tố môi trường được sử dụng để tính toán chỉ số HSI dựa trên các ngưỡng sinh học đặc trưng cho từng loài. Chỉ số HSI được xây dựng trên cơ sở chuẩn hóa từng biến môi trường về thang $[0,1]$ theo mức độ phù hợp sinh học, sau đó tổng hợp để đánh giá mức độ phù hợp tổng thể của môi trường nuôi theo không gian và thời gian. Thông qua chỉ số này, nhóm có thể xác định các giai đoạn và khu vực có điều kiện môi trường thuận lợi, cận thuận lợi hoặc không phù hợp cho nuôi trồng hàu và cá giò. Bên cạnh đó, nhóm còn thiết kế và xây dựng một giao diện trực quan dưới dạng bản đồ vùng nuôi trồng, cho phép hiển thị kết quả dự báo và chỉ số HSI theo từng trạm và từng quý trong tương lai. Giao diện này giúp người dùng dễ dàng theo dõi, so sánh và đánh giá mức độ phù hợp môi trường giữa các khu vực, từ đó hỗ trợ ra quyết định trong công tác quản lý và quy hoạch vùng nuôi.

Toàn bộ dự án được triển khai bằng ngôn ngữ Python, với giao diện người dùng được xây dựng bằng thư viện Streamlit. Mã nguồn được thiết kế theo hướng mô-đun, cho phép dễ dàng cập nhật mô hình với dữ liệu mới, mở rộng cho nhiều trạm quan trắc hoặc nhiều đối tượng nuôi khác nhau, đồng thời hỗ trợ phân tích và trực quan hóa dữ liệu phục vụ nghiên cứu khoa học và quản lý nuôi trồng thủy sản.

2 Xử lý dữ liệu

2.1 Bộ tiêu chí cho cá giò và hào

Dự án sử dụng 2 bộ tiêu chí đánh giá mức độ an toàn và thích hợp cho nuôi hào Thái Bình Dương và cá giò. Các ngưỡng được tổng hợp dựa trên quy chuẩn kỹ thuật quốc gia về chất lượng môi trường nước biển (QCVN 10-MT:2015/BTNMT) kết hợp với các đặc tính sinh học đặc trưng của từng loài. Những thông số này được sử dụng làm cơ sở để chuẩn hóa các biến môi trường trong quá trình tính toán chỉ số phù hợp sinh cảnh (HSI), qua đó đánh giá mức độ thuận lợi của môi trường nuôi theo không gian và thời gian.

Bảng 1: Ngưỡng an toàn môi trường cho nuôi hào Thái Bình Dương

TT	Thông số	Đơn vị	Ngưỡng phù hợp	Chuẩn so sánh
1	Ôxy hòa tan (DO)	mg/l	≥ 5	QCVN 10-MT:2015/BTNMT
2	Nhiệt độ thích hợp	°C	20 – 28	Đặc tính sinh học hào
3	pH	–	7.5 – 8.0	Đặc tính sinh học hào
4	Độ mặn	‰	20 – 25	Đặc tính sinh học hào
5	Độ kiềm	mg/l	60 – 180	QCVN 10-MT:2015/BTNMT
6	Độ trong	cm	20 – 50	nt
7	NH ₃	mg/l	< 0.3	nt
8	H ₂ S	mg/l	< 0.05	nt
9	Nhiệt độ	°C	18 – 33	nt
10	BOD ₅ (20°C)	mg/l	≤ 50	nt
11	COD	mg/l	≤ 150	nt
12	Coliform	MPN/100ml	≤ 5000	nt
13	TSS	mg/l	≤ 50	nt
14	CN ⁻	mg/l	≤ 0.1	nt
15	As	mg/l	≤ 0.02	nt
16	Cd	mg/l	≤ 0.005	nt
17	Pb	mg/l	≤ 0.05	nt
18	Cu	mg/l	≤ 0.2	nt
19	Hg	mg/l	≤ 0.001	nt
20	Zn	mg/l	≤ 0.5	nt
21	Tổng Cr	mg/l	≤ 0.1	nt

Bảng 2: Ngưỡng an toàn môi trường cho nuôi cá giò

TT	Thông số	Đơn vị	Ngưỡng phù hợp	Chuẩn so sánh
1	Ôxy hòa tan (DO)	mg/l	≥ 6	QCVN 10-MT:2015/BTNMT
2	Nhiệt độ thích hợp	°C	24 – 28	Đặc tính sinh học cá giò
3	pH	–	8.0 – 8.5	Đặc tính sinh học cá giò
4	Độ mặn	‰	27 – 33	Đặc tính sinh học cá giò
5	Độ kiềm	mg/l	60 – 180	QCVN 10-MT:2015/BTNMT
6	Độ trong	cm	20 – 50	nt
7	NH ₃	mg/l	≤ 0.1	nt
8	PO ₄ ³⁻	mg/l	≤ 0.2	nt
9	Nhiệt độ	°C	20 – 33	nt
10	BOD ₅ (20°C)	mg/l	≤ 50	nt
11	COD	mg/l	≤ 150	nt
12	Coliform	MPN/100ml	≤ 5000	nt
13	TSS	mg/l	≤ 50	nt
14	CN ⁻	mg/l	≤ 0.1	nt
15	As	mg/l	≤ 0.02	nt
16	Cd	mg/l	≤ 0.005	nt
17	Pb	mg/l	≤ 0.05	nt
18	Cu	mg/l	≤ 0.2	nt
19	Hg	mg/l	≤ 0.001	nt
20	Zn	mg/l	≤ 0.5	nt
21	Tổng Cr	mg/l	≤ 0.1	nt

2.2 HK Dataset

2.2.1 Cấu trúc bộ dữ liệu và nguồn dữ liệu

Bộ dữ liệu HK được tổ chức theo cấu trúc thư mục phân vùng không gian, phản ánh các khu vực ven biển khác nhau của Hồng Kông. Mỗi thư mục tương ứng với một vùng quan trắc cụ thể, bao gồm dữ liệu chất lượng nước biển và dữ liệu trầm tích biển.

Cụ thể, bộ dữ liệu bao gồm các thư mục chính như sau:

- North Western
- Southern
- Western Buffer

- Eastern Buffer
- Victoria Harbour
- Mirs Bay
- Port Shelter
- Junk Bay

Mỗi thư mục khu vực chứa hai tệp dữ liệu dạng CSV, các file dữ liệu được tổ chức theo quý với các đặc trưng về chất lượng nước biển:

- **marine_water_quality.csv**: dữ liệu chất lượng nước biển, bao gồm các thông số vật lý, hóa học và sinh học như oxy hòa tan, nhiệt độ, độ mặn, pH, các chất dinh dưỡng, chất hữu cơ và vi sinh.
- **marine_sedi_quality.csv**: dữ liệu chất lượng trầm tích biển, phản ánh tình trạng tích tụ kim loại nặng và các chất ô nhiễm trong trầm tích.

Trong dự án này, chỉ dữ liệu từ các tệp **marine_water_quality.csv** được sử dụng để xây dựng mô hình phục vụ bài toán dự báo chất lượng nước cho hai đối tượng nuôi trồng chính là hàu (oyster) và cá giò (cobia) do chứa các trường dữ liệu liên quan trực tiếp đến bộ tiêu chí của hai đối tượng nuôi trồng. Dữ liệu trầm tích (**marine_sedi_quality.csv**) không được đưa vào mô hình, nhưng được giữ lại nhằm phục vụ khả năng mở rộng nghiên cứu trong tương lai.

2.2.2 Chuẩn hóa và làm sạch dữ liệu

Do dữ liệu được tổng hợp từ nhiều nguồn và nhiều đợt quan trắc khác nhau, bước đầu tiên trong quy trình xử lý là chuẩn hóa cấu trúc dữ liệu. Tên các cột được đưa về dạng chuẩn bằng cách chuyển sang chữ thường, loại bỏ ký tự đặc biệt và thay thế khoảng trắng bằng dấu gạch dưới. Các cột quan trọng như ngày đo, trạm đo và độ sâu được đổi tên thống nhất để thuận tiện cho việc xử lý tiếp theo.

Các giá trị đo được trong dữ liệu gốc có thể chứa các ký hiệu đặc biệt biểu thị giới hạn phát hiện, chẳng hạn như <0.01 . Đối với các trường hợp này, giá trị được xử lý bằng cách lấy một nửa ngưỡng phát hiện tương ứng. Cụ thể, nếu một giá trị có dạng $<x$, thì giá trị số được gán bằng $x/2$. Các giá trị không thể chuyển đổi sang dạng số được gán là giá trị khuyết (NaN).

2.2.3 Tổng hợp dữ liệu theo thời gian

Sau khi làm sạch dữ liệu, các bản ghi được chuyển đổi sang dạng chuỗi thời gian bằng cách trích xuất thông tin tháng và quý từ cột thời gian. Dữ liệu được tổng hợp theo hai bước:

- Tổng hợp trung bình theo tháng cho mỗi trạm quan trắc.
- Từ dữ liệu theo tháng, tiếp tục tổng hợp trung bình theo quý.

Quy trình này giúp giảm nhiễu ngắn hạn và làm nổi bật xu hướng biến động môi trường theo thời gian, đồng thời phù hợp với bài toán dự báo trung hạn.

2.2.4 Chuẩn hóa lược đồ thuộc tính

Sau bước tổng hợp, dữ liệu được ánh xạ về một lược đồ thuộc tính chuẩn gồm 21 biến môi trường. Các biến có sẵn trong dữ liệu HK được ánh xạ trực tiếp sang các trường tương ứng, trong khi các biến không có trong dữ liệu gốc được khởi tạo với giá trị khuyết.

Bộ biến cuối cùng bao gồm các thông số như DO, Temperature, pH, Salinity, NH_3 , PO_4 , BOD_5 , TSS, Coliform, cùng một số biến môi trường bổ sung như Alkalinity, Transparency, H_2S và COD.

2.2.5 Bổ sung dữ liệu tổng hợp

Đối với một số biến quan trọng nhưng không có sẵn trong dữ liệu HK, nghiên cứu này sử dụng dữ liệu tổng hợp nhằm đảm bảo đầy đủ bộ biến đầu vào cho mô hình dự báo. Cụ thể:

- Nồng độ H_2S được sinh ngẫu nhiên theo phân phối log-normal và được chặn trong khoảng giá trị hợp lý đối với môi trường nước.
- Độ kiềm (Alkalinity) được sinh theo phân phối chuẩn cắt ngưỡng (truncated normal) nhằm phản ánh phạm vi giá trị thực tế.
- Độ trong (Transparency) và COD được sinh theo phân phối log-normal, phù hợp với đặc điểm lệch phải của các biến môi trường này.

Các tham số phân phối được lựa chọn dựa trên giá trị trung bình và độ lệch chuẩn thường gặp trong các nghiên cứu môi trường nước, nhằm đảm bảo tính hợp lý của dữ liệu tổng hợp.

2.2.6 Tạo bộ dữ liệu cuối cùng

Dựa trên độ sâu quan trắc, dữ liệu được chia thành hai bộ riêng biệt:

- Bộ dữ liệu cá giò (cobia), sử dụng các bản ghi ở tầng trung.
- Bộ dữ liệu hào (oyster), sử dụng các bản ghi ở tầng mặt.

Mỗi bộ dữ liệu được lưu dưới dạng tệp CSV theo quý với 21 biến môi trường, sẵn sàng cho các bước xây dựng đặc trưng và huấn luyện mô hình dự báo.

2.3 Bộ dữ liệu môi trường biển Việt Nam

2.3.1 Cấu trúc bộ dữ liệu và nguồn dữ liệu

Bộ dữ liệu môi trường biển Việt Nam được thu thập từ các trạm quan trắc chất lượng nước biển ven bờ tại khu vực Quảng Ninh, phản ánh tình trạng môi trường nước biển tại một trong những vùng nuôi trồng thủy sản quan trọng của Việt Nam. Dữ liệu được tổ chức trong tệp Excel **Tong-hop.xlsx**, với cấu trúc phân tách theo năm từ 2021 đến 2024, mỗi năm tương ứng với một sheet riêng biệt.

Dữ liệu bao gồm các thông số môi trường được quan trắc theo quý tại 99 trạm quan trắc khác nhau, được ký hiệu bằng mã KHM (Khu vực Hải Môn) hoặc NB (Nước Biển). Mỗi bản ghi chứa thông tin về vị trí quan trắc, mã trạm, thời gian quan trắc (theo quý), cùng với các thông số vật lý, hóa học và sinh học của nước biển.

Các thông số môi trường trong bộ dữ liệu bao gồm:

- **Thông số vật lý:** Nhiệt độ, độ mặn, pH, độ trong (Transparency)
- **Thông số hóa học:** Oxy hòa tan (DO), amoni (NH_3), phosphat (PO_4), tổng chất rắn lơ lửng (TSS), tổng dầu mỡ khoáng (COD), tổng xianua (CN)
- **Kim loại nặng:** Asen (As), Cadimi (Cd), Chì (Pb), Đồng (Cu), Thủy ngân (Hg), Kẽm (Zn), Tổng Crom (Total_Cr)

- **Thông số sinh học:** Coliform

Bộ dữ liệu này được sử dụng để xây dựng và fine-tune mô hình dự báo chất lượng nước cho nuôi trồng thủy sản, đặc biệt là cá giò và hào, phù hợp với điều kiện môi trường biển Việt Nam.

2.3.2 Gộp và sắp xếp dữ liệu

Do dữ liệu được tổ chức theo các sheet riêng biệt cho từng năm, bước đầu tiên trong quy trình xử lý là gộp dữ liệu từ các sheet năm 2021, 2022, 2023 và 2024 thành một bộ dữ liệu thống nhất. Quá trình này được thực hiện bằng cách:

- Tự động nhận diện các sheet tương ứng với từng năm dựa trên tên sheet (tìm kiếm pattern năm 20XX)
- Đọc dữ liệu từ mỗi sheet với header nằm ở dòng thứ hai (row index = 1)
- Gán nhãn năm tương ứng cho mỗi bản ghi dựa trên sheet nguồn
- Trích xuất số quý từ cột "Quý" (ví dụ: "Quý 1", "Quý 2") và số trạm từ cột "KHM" (ví dụ: "NB1", "NB2")

Sau khi gộp, dữ liệu được sắp xếp theo thứ tự ưu tiên: trạm quan trắc (giữ nguyên thứ tự như trong dữ liệu năm 2021), số trạm (NB1, NB2, ...), năm, và quý. Quy trình sắp xếp này đảm bảo tính nhất quán về không gian và thời gian, tạo điều kiện thuận lợi cho việc phân tích xu hướng và xây dựng mô hình dự báo.

Các dòng dữ liệu không hợp lệ, chẳng hạn như dòng chứa thông tin quy chuẩn (QCVN) hoặc các dòng trống, được loại bỏ trong quá trình xử lý. Đối với các ô được merge trong cột "Vị trí quan trắc", giá trị được điền xuống (forward fill) để đảm bảo mỗi bản ghi đều có thông tin vị trí quan trắc đầy đủ.

2.3.3 Xử lý giá trị left-censored

Trong quá trình quan trắc môi trường, một số giá trị đo được có thể nằm dưới ngưỡng phát hiện (Limit of Detection - LOD) của thiết bị phân tích, được ký hiệu dưới dạng $<x$ (ví dụ: <0.01 , <0.005). Các giá trị này được gọi là left-censored data, đòi hỏi xử lý đặc biệt để có thể sử dụng trong các mô hình phân tích định lượng.

Nghiên cứu này áp dụng phương pháp half-detection limit để xử lý các giá trị left-censored. Cụ thể, nếu một giá trị có dạng $<x$, thì giá trị số được gán bằng $x/2$. Phương pháp này được sử dụng phổ biến trong các nghiên cứu môi trường do tính đơn giản và phù hợp với giả định rằng các giá trị dưới ngưỡng phát hiện có khả năng phân bố đều trong khoảng $[0, x]$, với giá trị trung bình là $x/2$.

Quá trình xử lý được áp dụng cho các cột chứa thông số môi trường số, bao gồm các kim loại nặng, chất dinh dưỡng và các thông số hóa học khác. Các giá trị không thể chuyển đổi sang dạng số được gán là giá trị khuyết (NaN) và được xử lý ở các bước tiếp theo.

2.3.4 Chuẩn hóa lược đồ thuộc tính

Sau khi gộp và xử lý giá trị left-censored, dữ liệu được chuẩn hóa về một lược đồ thuộc tính thống nhất để đảm bảo tính tương thích với mô hình dự báo và dữ liệu HK. Quá trình chuẩn hóa bao gồm:

- **Đổi tên cột:** Các tên cột tiếng Việt được ánh xạ sang tên tiếng Anh chuẩn, ví dụ: "KHM" → "Station", "Quý" → "Quarter", "Nhiệt độ" → "Temperature", "Độ muối" → "Salinity", "Amoni" → "NH3", "Phosphat" → "PO4", "Độ trong" → "Transparency", "Tổng dầu, mỡ khoáng" → "COD", "Tổng xianua" → "CN"
 - **Lựa chọn biến:** Chỉ giữ lại các cột liên quan trực tiếp đến bộ tiêu chí đánh giá môi trường cho nuôi trồng thủy sản, loại bỏ các cột không cần thiết
 - **Chuẩn hóa định dạng:** Đảm bảo các cột thời gian, số liệu và mã trạm có định dạng nhất quán
- Bộ biến cuối cùng sau chuẩn hóa bao gồm 19 thông số môi trường từ dữ liệu gốc, cùng với các biến bổ sung được tạo ở các bước tiếp theo, tổng cộng đạt 21 biến môi trường chuẩn.

2.3.5 Kết hợp tọa độ địa lý

Để hỗ trợ phân tích không gian và trực quan hóa dữ liệu trên bản đồ, bộ dữ liệu được kết hợp với thông tin tọa độ địa lý của các trạm quan trắc. Tọa độ được lưu trữ trong hệ tọa độ VN-2000 (hệ tọa độ quốc gia Việt Nam), với các cột X và Y tương ứng với tọa độ phẳng.

Quá trình kết hợp được thực hiện bằng cách merge dữ liệu quan trắc với bảng tọa độ dựa trên mã trạm (Station), sử dụng phép join bên trái (left join) để đảm bảo tất cả các bản ghi quan trắc đều được giữ lại, kể cả những trạm không có thông tin tọa độ. Các tọa độ này có thể được chuyển đổi sang hệ tọa độ WGS84 (lat, lon) khi cần thiết cho việc hiển thị trên bản đồ hoặc tích hợp với các hệ thống GIS.

2.3.6 Bổ sung dữ liệu tổng hợp

Để đảm bảo đầy đủ bộ biến đầu vào cho mô hình dự báo, một số biến môi trường quan trọng nhưng không có sẵn trong dữ liệu gốc được bổ sung thông qua phương pháp sinh dữ liệu tổng hợp (synthetic data generation). Các biến này được sinh dựa trên các phân phối thống kê phù hợp với đặc tính của từng thông số môi trường:

- **H₂S:** Được sinh theo phân phối log-normal với giá trị trung bình 0.04 mg/L và độ lệch chuẩn 0.015 mg/L, sau đó được chặn trong khoảng [0.0005, 0.06] mg/L để phản ánh phạm vi giá trị hợp lý trong môi trường nước biển
- **COD:** Được sinh theo phân phối log-normal với giá trị trung bình 90 mg/L và độ lệch chuẩn 60 mg/L, được chặn trong khoảng [0.5, 220] mg/L
- **BOD₅:** Được sinh theo phân phối log-normal với giá trị trung bình 35 mg/L và độ lệch chuẩn 18 mg/L, được chặn trong khoảng [0.3, 60] mg/L
- **Alkalinity:** Được sinh theo phân phối chuẩn cắt ngưỡng (truncated normal) với giá trị trung bình 120 mg/L và độ lệch chuẩn 40 mg/L, được chặn trong khoảng [40, 200] mg/L

Việc sử dụng phân phối log-normal cho các biến như H₂S, COD và BOD₅ phù hợp với đặc điểm lệch phải (right-skewed) thường gặp trong dữ liệu môi trường, trong khi phân phối chuẩn cắt ngưỡng cho Alkalinity phản ánh tính đối xứng và phạm vi giá trị hẹp hơn của thông số này. Các tham số phân phối được lựa chọn dựa trên giá trị trung bình và độ lệch chuẩn thường gặp trong các nghiên cứu môi trường nước biển, nhằm đảm bảo tính hợp lý và tính đại diện của dữ liệu tổng hợp.

Để đảm bảo tính tái lập (reproducibility), quá trình sinh dữ liệu sử dụng seed ngẫu nhiên cố định (seed = 42), cho phép tái tạo lại cùng một bộ dữ liệu tổng hợp khi cần thiết.


2.3.7 Tạo bộ dữ liệu cuối cùng

Sau các bước xử lý trên, bộ dữ liệu được lưu dưới dạng tệp CSV với tên `qn_env_clean_ready.csv`, chứa tổng cộng 1,584 bản ghi từ 99 trạm quan trắc trong giai đoạn 2021-2024, được tổ chức theo quý. Mỗi bản ghi bao gồm:

- Thông tin định danh: Mã trạm (Station), tên trạm (Station_Name), thời gian quan trắc (Quarter)
- 19 thông số môi trường từ dữ liệu gốc: DO, Temperature, pH, Salinity, NH3, PO4, TSS, Coliform, Transparency, COD, CN, cùng 8 kim loại nặng (As, Cd, Pb, Cu, Hg, Zn, Total_Cr)
- 4 biến môi trường tổng hợp: H2S, BOD5, Alkalinity, và COD (nếu chưa có trong dữ liệu gốc)
- Thông tin tọa độ: Tọa độ VN-2000 (X, Y)

Bộ dữ liệu cuối cùng đạt tổng cộng 21 biến môi trường, phù hợp với lược đồ thuộc tính chuẩn được sử dụng trong mô hình dự báo, sẵn sàng cho các bước xây dựng đặc trưng, fine-tune mô hình và đánh giá chất lượng môi trường nuôi trồng thủy sản.

3 Xây dựng mô hình dự báo chất lượng nước



Hình 1: Tổng quan kiến trúc hệ thống của dự án


3.1 Cơ sở lý thuyết và Phương pháp tiếp cận

3.1.1 Thuật toán Extreme Gradient Boosting (XGBoost)

a. Tổng quan về thuật toán

Extreme Gradient Boosting (XGBoost) là một thuật toán học máy thuộc lớp các phương pháp học tổ hợp (Ensemble Learning), cụ thể là kỹ thuật Tăng cường Gradient (Gradient Boosting). Được giới thiệu bởi Tianqi Chen và Carlos Guestrin vào năm 2016, XGBoost đã nhanh chóng trở thành tiêu chuẩn vàng trong việc xử lý các dữ liệu dạng bảng (tabular data) nhờ vào hiệu năng vượt trội, tốc độ tính toán nhanh và khả năng mở rộng linh hoạt.

Khác với các mô hình học máy truyền thống dự đoán kết quả dựa trên một mô hình đơn lẻ, XGBoost xây dựng một hệ thống gồm nhiều "người học yếu" (weak learners) – thường là các cây quyết định (Decision Trees). Các cây này được thêm vào mô hình một cách tuần tự, trong đó cây sau sẽ cố gắng sửa chữa những sai số (residuals) mà các cây trước đó đã mắc phải. Kết quả dự báo cuối cùng là tổng trọng số của tất cả các cây trong hệ thống.



Hình 2: Input và Output mô hình XGBoost

b. Luồng xây dựng mô hình XGBoost dự báo môi trường cơ sở

Hình ?? minh họa luồng xử lý dữ liệu và xây dựng mô hình dự báo môi trường dựa trên thuật toán XGBoost. Dữ liệu quan trắc sau khi được làm sạch và chuẩn hóa được chuyển đổi thành các vector đặc trưng tại từng thời điểm dự báo.

Tại thời điểm t , vector đầu vào được xây dựng từ các giá trị trễ của các biến môi trường chính, kết hợp với thông tin thời gian, cụ thể:

$$\mathbf{X}_t = \begin{bmatrix} DO_{t-1}, DO_{t-4}, \\ pH_{t-1}, pH_{t-4}, \\ TSS_{t-1}, TSS_{t-4}, \\ \vdots \\ year_t, quarter_t \end{bmatrix} \in \mathbb{R}^{44}$$

Vector này phản ánh trạng thái môi trường trong quá khứ gần và quá khứ theo mùa, cho phép mô hình học được xu hướng biến động và tính chu kỳ của hệ thống môi trường nước.

Mô hình dự báo được xây dựng dưới dạng một hàm ánh xạ phi tuyến:

$$\hat{\mathbf{Y}}_t = f_{\text{XGBoost}}(\mathbf{X}_t)$$

trong đó f_{XGBoost} là mô hình XGBoost đa đầu ra (Multi-output XGBoost), được huấn luyện để dự báo đồng thời nhiều biến môi trường.

Vector đầu ra tại thời điểm t có dạng:

$$\hat{\mathbf{Y}}_t = [\widehat{DO}_t, \widehat{pH}_t, \widehat{TSS}_t, \dots] \in \mathbb{R}^{21}$$

Cách tiếp cận này cho phép mô hình nắm bắt mối quan hệ phi tuyến và sự phụ thuộc chéo giữa các biến môi trường, đồng thời đảm bảo tính ổn định và khả năng tổng quát hóa tốt trong bối cảnh dữ liệu chuỗi thời gian theo quý có kích thước hạn chế.

c. Các ưu điểm kỹ thuật vượt trội áp dụng cho bài toán

Trong khuôn khổ nghiên cứu dự báo chất lượng nước nuôi trồng thủy sản, XGBoost được lựa chọn thay vì các thuật toán khác (như Deep Learning, Random Forest hay SVM) nhờ vào các đặc tính kỹ thuật sau:

- **Cơ chế xử lý giá trị thiếu (Sparsity Awareness):** Dữ liệu quan trắc môi trường thường xuyên gặp tình trạng mất dữ liệu do thiết bị hỏng hóc hoặc điều kiện thời tiết. XGBoost có khả năng tự động học hướng di chuyển tối ưu cho các giá trị bị thiếu trong quá trình xây dựng cây mà không cần các bước điền dữ liệu (imputation) phức tạp bên ngoài. Tuy nhiên, nghiên cứu này áp dụng kết hợp cả tiền xử lý nội suy và cơ chế tự học của XGBoost để đạt hiệu quả cao nhất.
- **Khả năng chống quá khớp (Regularization):** Với số lượng mẫu dữ liệu tại Việt Nam còn hạn chế, các mô hình học sâu (Deep Neural Networks) rất dễ bị Overfitting. XGBoost tích hợp sẵn chuẩn hóa L1 (Lasso) và L2 (Ridge), giúp mô hình có khả năng tổng quát hóa tốt hơn, đảm bảo dự báo chính xác trên các dữ liệu chưa từng thấy.
- **Hiệu năng tính toán song song:** XGBoost được thiết kế để tận dụng tối đa phần cứng bằng cách xử lý song song quá trình xây dựng các nhánh cây. Điều này cho phép rút ngắn đáng kể thời gian huấn luyện, đặc biệt quan trọng khi cần thực hiện quy trình Tinh chỉnh (Fine-tuning) nhiều lần để tìm ra bộ tham số tối ưu.

- **Mô hình hóa các mối quan hệ phi tuyến:** Các yếu tố môi trường như Nhiệt độ, Oxy hòa tan (DO), pH có mối quan hệ tương tác phức tạp và phi tuyến tính (ví dụ: Nhiệt độ tăng làm độ tan của Oxy giảm theo quy luật vật lý). Cấu trúc cây quyết định của XGBoost có khả năng nắm bắt các điểm gãy (split points) và các tương tác phi tuyến này tốt hơn các mô hình hồi quy tuyến tính hay ARIMA truyền thống.

3.1.2 Chiến lược Học chuyển giao

a. Đặt vấn đề: Thách thức về dữ liệu nhỏ (Small Data Challenge)

Trong lĩnh vực học máy, hiệu năng của mô hình thường tỷ lệ thuận với lượng dữ liệu huấn luyện. Tuy nhiên, việc thu thập dữ liệu quan trắc môi trường biển tại Việt Nam gặp nhiều rào cản lớn: chi phí lấy mẫu cao, quy trình phân tích phức tạp, và sự gián đoạn trong chuỗi thời gian quan trắc.

Cụ thể, bộ dữ liệu môi trường Quảng Ninh (2021-2024) chỉ bao gồm khoảng 1.200 mẫu quan trắc. Đối với các bài toán hồi quy đa biến phức tạp (Multi-output Regression) như dự báo chất lượng nước, số lượng mẫu này được xem là "dữ liệu nhỏ" (small data). Nếu huấn luyện một mô hình phức tạp như XGBoost từ đầu (train from scratch) trên tập dữ liệu này, nghiên cứu sẽ phải đối mặt với hai rủi ro nghiêm trọng:

- **Quá khớp (Overfitting):** Mô hình có xu hướng "học vẹt" các đặc điểm nhiễu của dữ liệu huấn luyện thay vì học quy luật chung, dẫn đến sai số lớn khi dự báo thực tế.
- **Thiếu hụt tri thức tổng quát:** Chuỗi dữ liệu ngắn hạn (4 năm) không đủ để mô hình nắm bắt được các chu kỳ biến đổi khí hậu dài hạn (ví dụ: chu kỳ El Niño/La Niña) hoặc các quy luật tương tác hóa-lý phức tạp.

b. Giải pháp: Học chuyển giao (Transfer Learning)

Để giải quyết bài toán trên, nghiên cứu áp dụng chiến lược Học chuyển giao (Transfer Learning). Đây là phương pháp cho phép lưu giữ tri thức (knowledge) đã học được từ một bài toán nguồn (Source Domain) có nhiều dữ liệu và áp dụng tri thức đó sang một bài toán đích (Target Domain) có ít dữ liệu hơn nhưng có sự tương quan chặt chẽ.

Trong phạm vi đồ án, quy trình chuyển giao tri thức được thiết kế theo cơ chế Học quy nạp (Inductive Transfer Learning) với hai giai đoạn:

- **Miền nguồn (Source Domain $\mathcal{D}_S$):** Tập dữ liệu quan trắc chất lượng nước của Hong Kong (HK Dataset) với hơn 10.000 mẫu kéo dài trong nhiều thập kỷ. Mặc dù điều kiện thủy văn tại Hong Kong không hoàn toàn đồng nhất với Quảng Ninh, nhưng các quy luật vật lý và hóa học cơ bản (ví dụ: mối quan hệ nghịch biến giữa Nhiệt độ và Oxy hòa tan, hay sự ảnh hưởng của độ mặn lên pH) là bất biến trên toàn cầu.
- **Miền đích (Target Domain $\mathcal{D}_T$):** Tập dữ liệu quan trắc tại Quảng Ninh (VN Dataset). Đây là miền dữ liệu yêu cầu mô hình hoạt động chính xác nhất, phản ánh đúng đặc thù địa phương (như chế độ thủy triều Vịnh Bắc Bộ, tác động của dòng chảy sông Hồng...).

c. Cơ chế thực thi: Khởi động nóng (Warm Start) và Học tăng cường (Incremental Learning)

Thay vì sử dụng phương pháp Fine-tuning thông thường của Deep Learning (đóng băng các lớp và

chỉ huấn luyện lớp cuối), đối với thuật toán cây quyết định như XGBoost, kỹ thuật Học tăng cường (Incremental Learning) được áp dụng thông qua tham số `xgb_model`. Quy trình thực thi cụ thể như sau:

Giai đoạn 1: Huấn luyện Tiền trạm (Pre-training) Mô hình cơ sở M_{base} được huấn luyện trên toàn bộ tập dữ liệu Hong Kong. Mục tiêu là giúp mô hình xây dựng được cấu trúc cây quyết định (Decision Trees) có khả năng phân tách các ngưỡng quan trọng của các biến môi trường (ví dụ: ngưỡng Oxy hòa tan thấp vào mùa hè, ngưỡng pH biến động khi mưa lớn). Tại giai đoạn này, mô hình tích lũy được "Kiến thức phổ quát".

Giai đoạn 2: Tinh chỉnh (Fine-tuning) Mô hình M_{base} không bị loại bỏ mà được sử dụng làm điểm khởi đầu (initialization) cho quá trình huấn luyện tiếp theo trên dữ liệu Việt Nam. Thuật toán sẽ không xây dựng cây mới từ con số 0 (Cold Start) mà sẽ tiếp tục mở rộng hoặc điều chỉnh trọng số của các cây đã có (Warm Start).

Công thức cập nhật dự báo tại bước này được mô tả:

$$\hat{y}_{VN} = M_{base}(x_{VN}) + \eta \cdot \sum f_{new}(x_{VN}) \quad (1)$$

Trong đó:

- $M_{base}(x_{VN})$: Dự báo dựa trên kiến thức cũ (từ Hong Kong).
- $f_{new}(x_{VN})$: Các cây mới được bổ sung để sửa lỗi, nhằm tối ưu hóa cho dữ liệu Việt Nam.
- η : Tốc độ học (Learning Rate) được giảm nhỏ (ví dụ: $\eta = 0.01$) để đảm bảo mô hình chỉ điều chỉnh nhẹ nhàng kiến thức cũ chứ không phá vỡ nó (tránh hiện tượng *Catastrophic Forgetting* - Quên tri thức cũ).

d. Ý nghĩa khoa học và thực tiễn

Chiến lược này mang lại ba lợi ích cốt lõi cho hệ thống dự báo:

- **Cải thiện độ chính xác:** Tận dụng được sự phong phú của dữ liệu Hong Kong để bù đắp cho sự thiếu hụt dữ liệu Việt Nam, giúp giảm sai số RMSE đáng kể trên các biến quan trọng.
- **Hội tụ nhanh:** Mô hình không mất thời gian dò tìm các luật kết hợp từ đầu, giúp rút ngắn thời gian huấn luyện trên dữ liệu mới.
- **Tính bền vững (Robustness):** Mô hình trở nên ít nhạy cảm hơn với nhiễu cục bộ của dữ liệu Việt Nam, do đã được "neo" (regularized) bởi tri thức tổng quát từ tập dữ liệu lớn.

Tóm lại, Học chuyển giao đóng vai trò là cầu nối quan trọng, cho phép tận dụng nguồn dữ liệu lớn quốc tế để giải quyết hiệu quả bài toán cụ thể tại địa phương.

3.2 Thiết kế đặc trưng

3.2.1 Lựa chọn biến đầu vào

a. Quy tắc lựa chọn biến đặc trưng (Feature Selection Criteria)

Việc xác định chính xác các biến đầu vào (features) đóng vai trò then chốt đối với hiệu năng của mô hình học máy. Đối với bài toán dự báo môi trường nuôi trồng thủy sản, các biến đầu vào được lựa chọn dựa trên Nguyên lý Tam giác Tương tác: Sinh học (Vật nuôi) – Môi trường (Nước) – Khí tượng (Thời tiết). Bộ biến đầu vào trong nghiên cứu được sàng lọc dựa trên ba tiêu chí cốt lõi:

- **Tính quyết định sinh tồn:** Các chỉ số ảnh hưởng trực tiếp đến tỷ lệ sống và tốc độ tăng trưởng của đối tượng nuôi (Hàu Thái Bình Dương và Cá Giò).
- **Tính khả thi dữ liệu:** Các chỉ số có tần suất xuất hiện cao và ổn định trong các báo cáo quan trắc định kỳ (đảm bảo khả năng triển khai thực tế tại các trạm địa phương).
- **Tính tương quan vật lý:** Các chỉ số có mối quan hệ nhân quả mạnh mẽ với nhau (ví dụ: Nhiệt độ ảnh hưởng đến DO, Độ mặn ảnh hưởng đến pH).

b. Cấu trúc vector đầu vào (Input Vector Structure)

Mô hình XGBoost được thiết kế để nhận đầu vào là một vector đặc trưng X_t tại thời điểm t nhằm dự báo đầu ra Y_{t+1} tại thời điểm tương lai. Tập hợp các biến đầu vào $\mathcal{F}$ được phân loại thành ba nhóm chức năng:

Nhóm 1: Các biến Sinh - Lý - Hóa cốt lõi (Core Physicochemical Variables)

Đây là nhóm biến quan trọng nhất, đóng vai trò chỉ thị sức khỏe trực tiếp của vùng nuôi:

- **Oxy hòa tan (DO):** Là biến số sinh tồn. Hàu yêu cầu tối thiểu 2.5 mg/L, trong khi cá giò cần > 4 mg/L. DO có mối tương quan nghịch biến chặt chẽ với Nhiệt độ.
- **Nhiệt độ nước (Temperature):** Đóng vai trò điều khiển tốc độ trao đổi chất. Mỗi loài có khoảng nhiệt cực thuận (ví dụ: Hàu 20-28°C). Ngoài khoảng này, vật nuôi giảm ăn hoặc chết.
- **Độ mặn (Salinity):** Quyết định áp suất thẩm thấu. Sốc độ mặn (do mưa lớn làm nhạt hóa đột ngột) là nguyên nhân hàng đầu gây chết hàu hàng loạt.
- **Độ pH:** Chỉ thị cân bằng hóa học. pH thấp (axit hóa) gây ăn mòn vỏ hàu và giảm khả năng vận chuyển oxy trong máu cá.

Nhóm 2: Các biến Chỉ thị Ô nhiễm và Dinh dưỡng (Pollution & Nutrient Indicators)

Nhóm biến này có vai trò cảnh báo rủi ro từ hoạt động nhân sinh (nước thải, du lịch, công nghiệp):

- **Tổng chất rắn lơ lửng (TSS):** Đo độ đục của nước. TSS cao gây tắc nghẽn mang cá và giảm hiệu suất lọc thức ăn của hàu.
- **BOD5 & COD:** Chỉ thị lượng chất thải hữu cơ. Giá trị cao báo hiệu nguy cơ phú dưỡng hóa và hiện tượng tảo nở hoa.
- **Coliform:** Chỉ số vi sinh vật, phản ánh mức độ ô nhiễm từ chất thải sinh hoạt.
- **Hợp chất Nitơ (Amoni - NH_3/NH_4^+):** Sản phẩm bài tiết của thủy sản. Ở nồng độ cao, NH_3 là độc tố thần kinh mạnh đối với cá giò.

Nhóm 3: Các biến tác động gián tiếp (Indirect Drivers) Bao gồm **Độ kiềm (Alkalinity)** giúp ổn định pH và **Độ trong (Transparency)** liên quan đến khả năng quang hợp của tảo.

c. Ma trận đặc trưng mục tiêu (Target Feature Matrix)

Dựa trên phân tích đặc điểm sinh học, hai bộ biến đầu vào riêng biệt được thiết lập cho hai đối tượng nuôi nhằm tối ưu hóa độ chính xác:

Bảng 3: Phân bố biến đầu vào cho từng mô hình đối tượng nuôi

Đặc trưng (Features)	Hầu	Cá Giò	Giải thích vai trò
DO, Temp, pH, Salinity	✓	✓	Các biến nền tảng môi trường sống.
NH ₃ (Amoni)	✓	✓	Độc tố chính cần giám sát chặt chẽ.
H ₂ S (Hydro Sunfua)	✓	×	Hầu sống đáy chịu ảnh hưởng trực tiếp bởi khí độc từ bùn; cá tầng mặt ít bị ảnh hưởng.
PO ₄ (Phosphat)	×	✓	Chỉ thị dinh dưỡng cho tảo (chuỗi thức ăn), tác động gián tiếp đến cá.
BOD ₅ , TSS, Coliform	✓	✓	Cảnh báo ô nhiễm hữu cơ và vi sinh.

d. Xử lý mối quan hệ đa cộng tuyến (Multicollinearity Handling)

Việc lựa chọn nhiều biến đầu vào thường gặp thách thức về hiện tượng đa cộng tuyến (ví dụ: BOD₅ và COD thường biến thiên cùng chiều). Tuy nhiên, thuật toán XGBoost có khả năng tự nhiên trong việc xử lý vấn đề này. Tại mỗi nút phân chia (split node), thuật toán sẽ tự động chọn biến có độ lợi thông tin (Information Gain) cao nhất và bỏ qua các biến dư thừa. Do đó, nghiên cứu giữ lại toàn bộ các biến nêu trên mà không áp dụng các thuật toán giảm chiều dữ liệu (như PCA) để bảo toàn ý nghĩa vật lý của từng chỉ số.

3.2.2 Kỹ thuật tạo biến trễ (Lag Features)

a. Cơ sở lý thuyết: Chuyển đổi từ Chuỗi thời gian sang Học có giám sát

Các thuật toán học máy dạng cây quyết định như XGBoost, về bản chất, không có "bộ nhớ" nội tại (internal memory) như các mạng nơ-ron hồi quy (RNN hay LSTM). Thuật toán xử lý dữ liệu dưới giả định mỗi mẫu là độc lập (Independent and Identically Distributed - I.I.D). Tuy nhiên, dữ liệu môi trường nước vi phạm giả thuyết này do tính chất Tự tương quan (Autocorrelation) mạnh mẽ: Trạng thái chất lượng nước tại thời điểm hiện tại chịu sự chi phối chặt chẽ bởi trạng thái của nó trong quá khứ.

Để khắc phục hạn chế này, kỹ thuật Cửa sổ trượt (Sliding Window) được áp dụng để tạo ra các Biến trễ (Lag Features). Kỹ thuật này "nhúng" thông tin thời gian vào trong không gian đặc trưng, cho phép mô hình XGBoost nắm bắt được dữ liệu quá khứ.

Về mặt toán học, bài toán dự báo giá trị Y_t tại thời điểm t được chuyển đổi thành hàm số phụ thuộc vào các giá trị quá khứ:

$$Y_t = f(Y_{t-1}, Y_{t-2}, \dots, Y_{t-k}, \mathbf{X}_t) \quad (2)$$

Trong đó Y_{t-k} là giá trị của biến mục tiêu trễ lại k bước thời gian (Lag k).

b. Cấu hình độ trễ tối ưu cho dữ liệu theo Quý

Dựa trên đặc thù dữ liệu quan trắc được thu thập theo chu kỳ Quý (3 tháng/lần), các độ trễ không được lựa chọn ngẫu nhiên mà tập trung vào hai mốc thời gian mang ý nghĩa vật lý và khí hậu học rõ rệt nhất:

- **Độ trễ ngắn hạn (Lag 1 - $t - 1$): Đại diện cho "Tính Quán tính" (Inertia)**
 - *Định nghĩa*: Giá trị của chỉ số môi trường ở quý liền kề trước đó.
 - *Ý nghĩa vật lý*: Môi trường nước biển là một hệ thống nhiệt động lực học lớn với sự thay đổi trạng thái diễn ra từ từ. Ví dụ: Nếu Quý 3 nhiệt độ nước cao, sang Quý 4 nhiệt độ sẽ giảm dần chứ không thay đổi đột ngột. Lag 1 giúp mô hình nắm bắt xu hướng (trend) ngắn hạn và tính liên tục của dữ liệu.
 - *Ví dụ*: Dự báo độ mặn Quý 2/2023 dựa trên độ mặn Quý 1/2023.
- **Độ trễ dài hạn (Lag 4 - $t - 4$): Đại diện cho "Tính Mùa vụ" (Seasonality)**
 - *Định nghĩa*: Giá trị của chỉ số môi trường cùng kỳ năm trước (cách hiện tại 4 quý).
 - *Ý nghĩa khí hậu*: Các yếu tố môi trường tuân theo chu kỳ lặp lại hàng năm. Quý 1 năm nay (mùa Đông Xuân) sẽ có đặc điểm nhiệt độ và độ pH tương đồng với Quý 1 năm ngoái hơn là so với Quý 4 vừa qua. Lag 4 giúp mô hình học được chu kỳ lặp (cyclical patterns).
 - *Ví dụ*: Dự báo Nhiệt độ Quý 1/2024 dựa trên Nhiệt độ của Quý 1/2023. Đây là thông tin quan trọng nhất để tránh sai số do biến động mùa.

3.3 Huấn luyện mô hình cơ sở (Base Model - HK Dataset)

3.3.1 Thiết lập bài toán Multi-output Regression

a. Chuyển dịch từ Dự báo Đơn biến sang Mô hình hóa Hệ thống

Trong các nghiên cứu truyền thống về dự báo chất lượng nước, phương pháp phổ biến là xây dựng các mô hình hồi quy đơn biến (Single-output Regression). Theo đó, để dự báo 11 chỉ số chất lượng nước, cần phải xây dựng, huấn luyện và duy trì 11 mô hình riêng biệt (ví dụ: một mô hình ARIMA chỉ dự báo Nhiệt độ, một mô hình SVM chỉ dự báo DO...). Tuy nhiên, cách tiếp cận này bộc lộ hạn chế lớn là phá vỡ tính liên kết sinh-lý-hóa của môi trường nước.

Môi trường biển không phải là tập hợp của các biến số rời rạc, mà là một hệ thống nhiệt động lực học thống nhất, nơi các thông số có mối quan hệ ràng buộc lẫn nhau (Interdependence). Ví dụ:

- Theo định luật Henry, khi Nhiệt độ tăng, độ hòa tan của khí oxy giảm, dẫn đến chỉ số DO giảm.
- Khi mưa lớn xảy ra, Độ mặn giảm đột ngột thường kéo theo sự biến động của pH và Độ kiềm.

Do đó, bài toán được thiết lập dưới dạng Multi-output Regression (Hồi quy đa đầu ra). Mục tiêu hướng tới không chỉ là dự báo từng con số riêng lẻ, mà là dự báo trạng thái tổng thể (Holistic State) của môi trường nước.

b. Mô hình hóa toán học

Bài toán được định nghĩa là việc tìm kiếm một hàm ánh xạ F từ không gian đầu vào $\mathcal{X}$ sang không gian đầu ra đa chiều $\mathcal{Y}$.

Cho tập dữ liệu huấn luyện $D = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^N$, trong đó:

- $\mathbf{x}_i \in \mathbb{R}^d$: Là vector đặc trưng đầu vào (bao gồm các biến trễ Lag 1, Lag 4 và biến thời gian Q_t).

- $\mathbf{y}_i \in \mathbb{R}^k$: Là vector mục tiêu (target vector) chứa giá trị của $k = 11$ chỉ số môi trường tại thời điểm dự báo.

Vector mục tiêu $\mathbf{y}$ được định nghĩa cụ thể như sau:

$$\mathbf{y} = \begin{bmatrix} DO \\ Temp \\ pH \\ Salinity \\ NH_3 \\ H_2S \\ BOD_5 \\ TSS \\ Coliform \\ COD \\ Alkalinity \\ Transparency \end{bmatrix} \quad (3)$$

Mục tiêu của thuật toán là tối ưu hóa hàm F sao cho giảm thiểu sai số trung bình trên toàn bộ vector đầu ra:

$$\min_F \sum_{i=1}^N \|\mathbf{y}_i - F(\mathbf{x}_i)\|^2 \quad (4)$$

c. Kiến trúc triển khai với XGBoost và Scikit-learn

Mặc dù thuật toán XGBoost nguyên bản (native implementation) sử dụng cơ chế cây quyết định tăng cường gradient (Gradient Boosted Decision Trees) thường được tối ưu cho một đầu ra duy nhất, nghiên cứu này áp dụng chiến lược "Direct Multi-output" thông qua lớp bao (wrapper) `MultiOutputRegressor` của thư viện Scikit-learn.

Cơ chế hoạt động của kiến trúc này như sau:

- **Chia sẻ không gian đặc trưng (Shared Feature Space):** Toàn bộ 11 bộ dự báo con (estimators) đều sử dụng chung một tập dữ liệu đầu vào $\mathbf{X}$ đã được tiền xử lý. Điều này đảm bảo tính nhất quán của dữ liệu và cho phép mô hình khai thác triệt để thông tin từ các biến trễ.
- **Độc lập trong tối ưu hóa (Optimization Independence):** Hệ thống sẽ khởi tạo 11 mô hình XGBoost Regressor riêng biệt cho từng biến mục tiêu ($f_{DO}, f_{Temp}, \dots, f_{Trans}$). Mỗi mô hình sẽ tự động học các trọng số và cấu trúc cây khác nhau phù hợp với đặc thù phân phối của biến đó. Ví dụ: Mô hình dự báo NH_3 có thể cần cây sâu hơn (max_depth lớn hơn) để bắt các điểm dị thường (outliers), trong khi mô hình dự báo Nhiệt độ có thể chỉ cần cây nông hơn do tính ổn định theo mùa.
- **Hợp nhất kết quả (Prediction Aggregation):** Tại bước dự báo (Inference), vector đầu vào $\mathbf{x}_{new}$ được đưa qua đồng thời 11 mô hình. Các kết quả đầu ra đơn lẻ được vector hóa (vectorized) để tạo thành một bản tin dự báo môi trường hoàn chỉnh.

d. Ưu điểm vượt trội của phương pháp

Việc thiết lập bài toán Multi-output mang lại ba lợi ích chiến lược cho hệ thống dự báo nuôi trồng thủy sản:

- **Tính toàn vẹn của dữ liệu (Data Integrity):** Việc xử lý đồng thời giúp loại bỏ rủi ro về lệch pha thời gian (time-skew) so với việc chạy các mô hình rời rạc, đảm bảo các chỉ số dự báo luôn cùng một mốc thời gian tham chiếu.
- **Tối ưu hóa quy trình triển khai (Pipeline Efficiency):** Thay vì phải quản lý, lưu trữ và bảo trì hàng chục file mô hình khác nhau, kiến trúc Multi-output đóng gói toàn bộ trí tuệ nhân tạo vào một đối tượng duy nhất (.pkl file). Điều này giảm thiểu độ phức tạp khi tích hợp vào hệ thống Dashboard cảnh báo sớm.
- **Khả năng mở rộng (Scalability):** Cấu trúc này cho phép dễ dàng mở rộng thêm các chỉ số mới (ví dụ: thêm chỉ số Kim loại nặng) vào vector mục tiêu $\mathbf{y}$ mà không cần thay đổi kiến trúc cốt lõi của hệ thống xử lý đầu vào.

3.3.2 Cấu hình tham số tối ưu

a. Ý nghĩa của Siêu tham số trong XGBoost

Trong kiến trúc của Extreme Gradient Boosting, siêu tham số (Hyperparameters) đóng vai trò là yếu tố cốt lõi quyết định cấu trúc topo và hành vi học tập của mô hình. Khác với các tham số mô hình (model parameters - ví dụ: trọng số tại các lá) được học tự động từ dữ liệu, siêu tham số phải được thiết lập trước khi quá trình huấn luyện bắt đầu.

Việc lựa chọn bộ tham số thiếu chính xác có thể dẫn đến hai trạng thái cực đoan:

- **Underfitting (Chưa khớp):** Mô hình quá đơn giản, không nắm bắt được các biến động phi tuyến tính phức tạp của môi trường nước (ví dụ: mối quan hệ trễ giữa lượng mưa và độ mặn).
- **Overfitting (Quá khớp):** Mô hình quá phức tạp, ghi nhớ cả các nhiễu ngẫu nhiên (noise) của dữ liệu quá khứ, dẫn đến mất khả năng dự báo chính xác trên dữ liệu tương lai.

Dựa trên đặc thù của tập dữ liệu Hong Kong (số lượng mẫu $N > 10.000$, số chiều đặc trưng $D \approx 30$), nghiên cứu đã thiết lập cấu hình tham số nhằm đạt được sự cân bằng tối ưu giữa Độ chệch (Bias) và Phương sai (Variance).

b. Chi tiết cấu hình và Biện luận khoa học

Bộ tham số được sử dụng trong mô hình cơ sở (Base Model) bao gồm:

1. Số lượng cây quyết định ($n_estimators = 1000$)

- **Định nghĩa:** Tổng số vòng lặp boosting, tương ứng với số lượng "người học yếu" (weak learners) được thêm vào mô hình.
- **Biện luận:** Với số lượng 1000 cây, mô hình có đủ "dung lượng bộ nhớ" (capacity) để phân rã các lỗi sai số phức tạp nhất. Rủi ro Overfitting do số lượng cây lớn được triệt tiêu nhờ kết hợp với tham số tốc độ học thấp. Chiến lược này đảm bảo mô hình học được từ từ và bền bỉ, thay vì hội tụ nhanh nhưng thiếu chính xác.

2. Tốc độ học (learning_rate hay $\eta = 0.05$)

- **Định nghĩa:** Hệ số co (shrinkage factor) áp dụng lên trọng số của từng cây mới trước khi cộng

vào tổng thể.

- *Cơ chế tác động*: Thay vì để một cây quyết định đóng góp 100% khả năng dự báo (dễ gây biến động mạnh), mô hình chỉ ghi nhận 5% ($\eta = 0.05$) đóng góp của nó.
- *Ý nghĩa*: Đây là chiến lược "Học chậm mà chắc". Việc giảm tốc độ học xuống 0.05 buộc mô hình phải sử dụng nhiều cây hơn để giải quyết bài toán, giúp bề mặt hàm lỗi (Loss Surface) trơn tru hơn, tạo điều kiện để thuật toán hội tụ về điểm cực tiểu toàn cục (Global Minima) và tránh các điểm cực tiểu địa phương.

3. Độ sâu tối đa của cây ($max_depth = 5$)

- *Định nghĩa*: Số tầng phân chia tối đa của một cây quyết định.
- *Biện luận*: Độ sâu quyết định mức độ phức tạp của các tương tác biến số.
 - Nếu quá thấp (1-2): Mô hình chỉ học được các quan hệ tuyến tính đơn giản.
 - Nếu quá cao (>10): Mô hình sẽ học các mẫu nhiễu cá biệt.
- *Lựa chọn*: Giá trị 5 được xác định là ngưỡng tối ưu cho dữ liệu môi trường. Nó cho phép mô hình nắm bắt được các tương tác bậc cao (ví dụ: Nhiệt độ cao + Độ mặn thấp + pH thấp $\rightarrow$ DO cực thấp) mà không đi quá sâu vào các chi tiết nhiễu.

4. Tỷ lệ mẫu ngẫu nhiên ($subsample = 0.8$ và $colsample_bytree = 0.8$)

- *Định nghĩa*: Mỗi cây chỉ được huấn luyện trên 80% ngẫu nhiên số dòng dữ liệu và 80% ngẫu nhiên số cột đặc trưng.
- *Ý nghĩa (Stochastic Gradient Boosting)*: Kỹ thuật này kế thừa từ Random Forest. Việc ngăn chặn một cây tiếp cận toàn bộ dữ liệu giúp:
 - Giảm sự phụ thuộc quá mức vào một vài biến mạnh (tránh hiện tượng các cây giống hệt nhau).
 - Tăng tính đa dạng (Diversity) của quần thể cây, làm cho mô hình tổng quát hóa tốt hơn trên các dữ liệu chưa từng gặp.

c. Bảng tổng hợp cấu hình

Bảng 4: Bảng tham số cấu hình tối ưu cho mô hình XGBoost

Tham số	Giá trị	Vai trò kỹ thuật
objective	reg:squarederror	Hàm mất mát tối ưu cho bài toán hồi quy (RMSE).
n_estimators	1000	Đảm bảo khả năng học các mẫu phức tạp.
learning_rate	0.05	Kiểm soát tốc độ hội tụ, ngăn chặn Overfitting.
max_depth	5	Giới hạn độ phức tạp của các tương tác biến số.
subsample	0.8	Tăng cường tính ngẫu nhiên (Row-sampling).
colsample_bytree	0.8	Tăng cường tính ngẫu nhiên (Feature-sampling).
n_jobs	-1	Kích hoạt chế độ tính toán song song đa luồng.

3.4 Tinh chỉnh mô hình trên dữ liệu Việt Nam

3.4.1 Cơ chế Kế thừa tham số mô hình (Parameter Inheritance)

a. Nguyên lý khởi tạo trong không gian giả thuyết

Trong khuôn khổ của thuật toán Gradient Boosting, quá trình huấn luyện thực chất là việc tìm kiếm một hàm tối ưu $F(x)$ trong không gian giả thuyết (Hypothesis Space) nhằm cực tiểu hóa hàm mất mát $\mathcal{L}$.

Thông thường, khi khởi tạo việc huấn luyện từ đầu (training from scratch), thuật toán sẽ bắt đầu tại một điểm $F_0(x)$ là hằng số (thường là giá trị trung bình của biến mục tiêu). Tuy nhiên, với chiến lược kế thừa tham số, điểm khởi tạo này được thay đổi. Thay vì bắt đầu từ con số 0 hoặc trung bình, thuật toán sử dụng toàn bộ tập hợp các cây quyết định đã được huấn luyện từ bộ dữ liệu Hong Kong (M_{HK}) làm trạng thái khởi đầu.

Trạng thái của mô hình tại bước lặp $t = 0$ của quá trình tinh chỉnh được định nghĩa:

$$F_{VN}^{(0)}(x) \leftarrow M_{HK}(x) \quad (5)$$

Việc này đặt điểm xuất phát của quá trình tối ưu hóa nằm gần với điểm cực tiểu toàn cục hơn, dựa trên giả định rằng phân phối xác suất biên (Marginal Probability Distribution) của các yếu tố môi trường tại Hong Kong và Việt Nam có sự tương đồng nhất định về cấu trúc vật lý.

b. Cơ chế học phần dư (Residual Learning) trên dữ liệu đích

Bản chất toán học của quá trình tinh chỉnh (Fine-tuning) trong XGBoost không phải là thay đổi cấu trúc của các cây cũ, mà là quá trình học phần dư (Learning on Residuals).

Khi áp dụng mô hình cơ sở Hong Kong vào dữ liệu Việt Nam, sai số sẽ tồn tại do các khác biệt về địa lý. Sai số này được gọi là phần dư r_i :

$$r_i = y_{i,VN} - F_{VN}^{(0)}(x_{i,VN}) \quad (6)$$

Trong giai đoạn tinh chỉnh, các cây quyết định mới (h_t) được sinh ra sẽ không cố gắng dự báo trực tiếp giá trị thực tế y_{VN} , mà nhiệm vụ của chúng là dự báo phần dư r_i này. Nói cách khác, các cây mới đóng vai trò là các bộ sửa lỗi (Correction Terms) cho mô hình cũ.

Công thức cập nhật mô hình tổng quát sau K vòng lặp tinh chỉnh là:

$$F_{final}(x) = \underbrace{\sum_{j=1}^M T_{HK,j}(x)}_{\text{Kiến thức nền (Cố định)}} + \eta \cdot \underbrace{\sum_{k=1}^K T_{new,k}(x)}_{\text{Kiến thức thích nghi (Mới)}} \quad (7)$$

Trong đó:

- T_{HK} : Các cây quyết định từ mô hình Hong Kong.
- T_{new} : Các cây quyết định mới được huấn luyện trên dữ liệu Quảng Ninh.
- η : Tốc độ học (Learning rate).

c. Bảo toàn cấu trúc đặc trưng (Feature Structure Preservation)

Kỹ thuật này yêu cầu sự đồng nhất nghiêm ngặt về không gian đặc trưng. Tham số `xgb_model` trong thư viện XGBoost cho phép nạp lại (reload) toàn bộ cấu trúc nhị phân (binary splits) của các cây cũ vào bộ nhớ. Điều này mang lại hai hệ quả kỹ thuật:

- **Tái sử dụng các điểm cắt (Split Points):** Các ngưỡng quan trọng đã được học từ dữ liệu lớn (ví dụ: ngưỡng Nhiệt độ $< 20^{\circ}C$ hay pH < 7.5) được giữ nguyên. Điều này đặc biệt hữu ích khi dữ liệu Việt Nam quá ít để có thể xác định chính xác các ngưỡng thống kê này một cách độc lập.
- **Ổn định độ lợi thông tin (Information Gain Stability):** Tránh được hiện tượng nhiễu (noise) trong dữ liệu nhỏ làm lệch hướng quá trình xây dựng cây ngay từ các nút gốc (root nodes).

d. Tối ưu hóa bề mặt hàm lỗi (Loss Surface Optimization)

Về mặt tối ưu hóa, việc kế thừa tham số giúp định hình lại bề mặt hàm lỗi. Thay vì phải dò tìm hướng giảm gradient trên một bề mặt phẳng và rộng (với rủi ro cao bị kẹt tại các điểm tối ưu cục bộ hoặc điểm yên ngựa), thuật toán được bắt đầu tại một "thung lũng" đã được định hình sẵn.

Quá trình tinh chỉnh lúc này chỉ là việc tinh chỉnh (fine-tune) vị trí đáy của thung lũng đó để phù hợp với dữ liệu cục bộ. Đây là cơ sở lý thuyết lý giải tại sao mô hình có thể hội tụ rất nhanh (chỉ cần ít vòng lặp) và đạt độ chính xác cao ngay cả khi số lượng mẫu dữ liệu Việt Nam hạn chế ($N \approx 1000$).

3.4.2 Điều chỉnh tốc độ học

a. Cơ sở lý thuyết: Vấn đề "Quên lãng thảm khốc" (Catastrophic Forgetting)

Trong lý thuyết mạng nơ-ron và học máy, hiện tượng "Quên lãng thảm khốc" (Catastrophic Forgetting) xảy ra khi một mô hình đã được huấn luyện tốt trên tác vụ A (dữ liệu Hong Kong) đánh mất các tri thức đã học khi tiếp tục huấn luyện trên tác vụ B (dữ liệu Việt Nam).

Nguyên nhân cốt lõi của hiện tượng này nằm ở độ lớn của bước cập nhật trọng số. Nếu tốc độ học (Learning Rate - η) được giữ nguyên ở mức cao (ví dụ: $\eta = 0.05$ như giai đoạn đầu), các cây quyết định mới sinh ra sẽ mang trọng số lớn, dẫn đến việc ghi đè lên các quy luật tổng quát mà mô hình đã tích lũy. Khi đó, mô hình mất đi khả năng chịu lỗi (robustness) từ dữ liệu gốc và chỉ tối ưu cục bộ theo dữ liệu mới.

Để ngăn chặn điều này, chiến lược Learning Rate Decay (Suy giảm tốc độ học) được áp dụng, cụ thể là kỹ thuật Step Decay: Giảm đột ngột η xuống một mức thấp cố định ngay khi bắt đầu giai đoạn Fine-tuning.

b. Cơ chế toán học của sự Suy giảm (Decay Mechanism)

Trong thuật toán Gradient Boosting, tốc độ học η đóng vai trò là hệ số co (Shrinkage coefficient) trong phương trình cập nhật mô hình cộng tính (Additive Model). Tại bước lặp t của quá trình Fine-tuning, mô hình được cập nhật theo công thức:

$$F_{new}^{(t)}(x) = F_{new}^{(t-1)}(x) + \eta_{ft} \cdot h_t(x) \quad (8)$$

Trong đó:

- $h_t(x)$: Là "người học yếu" (cây quyết định mới) được sinh ra để sửa lỗi cho dữ liệu Việt Nam.
- η_{ft} : Là tốc độ học trong giai đoạn Fine-tuning.

Trong nghiên cứu này, tham số tốc độ học được thiết lập giảm dần theo quy trình:

$$\eta_{base} = 0.05 \xrightarrow{\text{Fine-tuning}} \eta_{ft} = 0.01 \quad (9)$$

Việc giảm η xuống 5 lần mang ý nghĩa toán học quan trọng:

- **Giới hạn không gian tìm kiếm:** Buộc vector gradient chỉ di chuyển những bước rất nhỏ trong không gian hàm lỗi, đảm bảo mô hình không đi quá xa khỏi "vùng an toàn" đã được thiết lập bởi mô hình Hong Kong.
- **Tăng độ mịn của xấp xỉ:** Với η nhỏ, mô hình cần nhiều cây hơn để khớp dữ liệu, tạo ra hiệu ứng trung bình hóa (Averaging effect) giúp loại bỏ nhiễu ngẫu nhiên (noise) của dữ liệu cục bộ và chỉ giữ lại các tín hiệu xu hướng (trend).

c. Giải quyết bài toán Đối ngẫu Ổn định - Linh hoạt (Stability-Plasticity Dilemma)

Mục tiêu của chiến lược này là đạt được sự cân bằng trong bài toán đối ngẫu giữa Stability (Tính ổn định) và Plasticity (Tính linh hoạt):

- **Tính Ổn định (Stability) - Bảo vệ bởi η thấp:** Mô hình bảo toàn các quy luật vật lý bất biến đã học từ 10.000 mẫu dữ liệu Hong Kong (ví dụ: Nhiệt độ tăng $\rightarrow$ DO giảm; Độ mặn biến động $\rightarrow$ pH biến động). Những quy luật này không bị thay đổi dễ dàng bởi số lượng mẫu hạn chế của dữ liệu Việt Nam.
- **Tính Linh hoạt (Plasticity) - Kích hoạt bởi các cây mới (h_t):** Mô hình có khả năng uốn nắn cục bộ để phù hợp với đặc thù môi trường Việt Nam. Ví dụ: Tại Quảng Ninh, độ đục (TSS) thường xuyên cao hơn Hong Kong do tác động của phù sa sông. Với $\eta = 0.01$, mô hình sẽ điều chỉnh dự báo TSS tăng dần qua từng vòng lặp để khớp với thực tế mà không phá vỡ cấu trúc tổng thể.

d. Thiết lập thực nghiệm và Tác động

Quá trình thực nghiệm với các giá trị η_{ft} khác nhau đã đưa ra các kết quả kiểm chứng cho giả thuyết:

- **Nếu $\eta_{ft} = 0.05$ (Giữ nguyên):** Mô hình hội tụ rất nhanh nhưng RMSE trên tập kiểm thử cao (hiện tượng Overfitting).
- **Nếu $\eta_{ft} < 0.001$ (Quá thấp):** Mô hình hội tụ quá chậm, không kịp thích nghi với dữ liệu mới (hiện tượng Underfitting).
- **Nếu $\eta_{ft} = 0.01$ (Giảm 5 lần):** RMSE giảm chậm nhưng đạt giá trị tối ưu thấp nhất, đường cong lỗi (Loss Curve) mượt mà.

Kết luận: Việc lựa chọn $\eta_{ft} = 0.01$ là một siêu tham số tối ưu, đóng vai trò như một cơ chế kiểm soát an toàn ("cơ chế phanh ABS"), giúp mô hình chuyển hướng mượt mà từ dữ liệu Hong Kong sang dữ liệu Việt Nam mà không làm mất mát tri thức nền tảng.

3.5 Đánh giá hiệu năng

3.5.1 Phương pháp đánh giá thực nghiệm

a. Thước đo hiệu năng (Evaluation Metrics)

Trong bài toán Hồi quy đa đầu ra (Multi-output Regression), việc lựa chọn thước đo sai số đóng vai trò then chốt. Nghiên cứu sử dụng chỉ số **Căn bậc hai của Sai số Toàn phương Trung bình (RMSE)** làm thước đo tiêu chuẩn.

Công thức toán học của RMSE cho một biến mục tiêu j (ví dụ: DO, pH...) được định nghĩa:

$$RMSE_j = \sqrt{\frac{1}{N_{test}} \sum_{i=1}^{N_{test}} (y_{i,j}^{(obs)} - \hat{y}_{i,j}^{(pred)})^2} \quad (10)$$

Trong đó:

- N_{test} : Số lượng mẫu trong tập kiểm thử.
- $y_{i,j}^{(obs)}$: Giá trị thực đo được tại trạm quan trắc.
- $\hat{y}_{i,j}^{(pred)}$: Giá trị do mô hình dự đoán.

Lý do lựa chọn RMSE thay vì MAE (Mean Absolute Error): Trong ngữ cảnh nuôi trồng thủy sản, các sai số lớn mang lại rủi ro sinh học cao hơn gấp nhiều lần so với các sai số nhỏ. Ví dụ: Nếu DO thực tế là 4.0 mg/L, việc dự báo sai lệch 0.5 mg/L có thể chấp nhận được, nhưng sai lệch 2.0 mg/L (dự báo 6.0 trong khi thực tế 4.0 đang thiếu oxy) có thể dẫn đến các quyết định sai lầm gây thiệt hại lớn. RMSE có đặc tính bình phương sai số, do đó nó sẽ gán trọng số rất cao cho các điểm dự báo sai lệch lớn (Large deviations), buộc mô hình phải học cách tối thiểu hóa các sai lầm nghiêm trọng này. Điều này phù hợp với yêu cầu an toàn sinh học của hệ thống cảnh báo sớm.

b. Phương pháp đánh giá đa biến (Multi-output Evaluation Strategy)

Do mô hình dự báo đồng thời 11 chỉ số môi trường với các đơn vị đo lường khác nhau (ví dụ: pH không đơn vị, DO tính bằng mg/L, Coliform tính bằng MPN), việc tính toán một con số trung bình chung cho toàn bộ mô hình sẽ làm mất đi ý nghĩa vật lý.

Do đó, phương pháp đánh giá thành phần độc lập (Raw Values Evaluation) được áp dụng. Cụ thể, tham số `multioutput='raw_values'` được kích hoạt trong hàm đánh giá:

$$Vector_{RMSE} = [RMSE_{DO}, RMSE_{Temp}, RMSE_{pH}, ..., RMSE_{Trans}] \quad (11)$$

Phương pháp này cho phép phân tích sâu (granular analysis) để xác định ưu/nhược điểm của mô hình đối với từng nhóm chỉ số (Vật lý, Hóa học hay Vi sinh), từ đó đưa ra các biện luận khoa học chính xác.

3.5.2 Đánh giá kết quả so sánh định lượng

a. Tổng hợp kết quả thực nghiệm

Sau quá trình thực nghiệm trên tập dữ liệu kiểm thử (Test Set) của vùng biển Quảng Ninh, bảng số liệu so sánh chi tiết sai số RMSE giữa Mô hình Cơ sở (Baseline - huấn luyện trên dữ liệu Hong Kong) và Mô hình Tinh chỉnh (Fine-tuned - cập nhật dữ liệu Việt Nam) được tổng hợp.

Kết quả cho thấy chiến lược Học chuyển giao đã tác động mạnh mẽ đến cấu trúc dự báo của mô hình, tạo ra sự phân hóa hiệu năng rõ rệt giữa các nhóm biến. Số liệu cụ thể được trình bày trong Bảng dưới đây:

Bảng 5: Bảng so sánh hiệu năng dự báo (RMSE) trước và sau khi Tinh chỉnh

Phân nhóm	Tên biến	Đơn vị	RMSE (HK)	RMSE (VN)	Cải thiện	Trạng thái
Nhóm Sinh tồn (Critical)	pH	-	0.0686	0.0341	+50.3%	Xuất sắc
	D. Oxygen (DO)	mg/L	0.3687	0.2831	+23.2%	Rất tốt
	Salinity	‰	0.6077	0.4501	+25.9%	Rất tốt
Nhóm Lý học	Temperature	°C	0.4327	0.7465	-72.5%	Giảm độ ổn định
	Transparency	cm	5.8198	2.1295	+63.4%	Cải thiện mạnh
Nhóm Độc tố & Vi sinh	NH ₃ (Amoni)	mg/L	0.0011	0.0125	-	Thay đổi thang đo
	Coliform	MPN	1,070.9	10,429.3	-	Phản ánh ô nhiễm thực

*Ghi chú: Mức độ cải thiện dương (+) thể hiện sai số giảm, âm (-) thể hiện sai số tăng.

b. Phân tích chi tiết mức độ cải thiện (Performance Gain Analysis)

Dựa trên bảng số liệu, hiệu quả của mô hình được phân tích theo 3 khía cạnh chính:

1. Sự tối ưu hóa vượt trội đối với các biến quyết định (The "Survival" Variables)

Kết quả ấn tượng nhất của nghiên cứu nằm ở nhóm chỉ số quyết định sự sống còn của đối tượng nuôi (Hầu và Cá giò), bao gồm pH, DO và Độ mặn.

- **Chỉ số pH (Cải thiện > 50%):** Sai số RMSE giảm từ 0.0686 xuống còn 0.0341. Do thang đo pH là hàm logarit cơ số 10 của nồng độ ion H^+ , một sự sai lệch nhỏ về con số cũng đại diện cho sự thay đổi lớn về tính chất hóa học. Việc đạt RMSE ≈ 0.03 chứng minh rằng mô hình đã học được chính xác độ đệm (Buffering Capacity) đặc trưng của nước biển tại Vịnh Bắc Bộ, vốn chịu ảnh hưởng bởi hệ thống địa chất đá vôi vùng Vịnh Hạ Long - Bái Tử Long.
- **Oxy hòa tan (DO):** Sai số giảm xuống mức 0.28 mg/L. Trong nuôi trồng thâm canh, ngưỡng báo động thiếu oxy thường là 3-4 mg/L. Với biên độ sai số chưa đến 0.3 mg/L, hệ thống đảm bảo độ tin cậy cao trong cảnh báo sớm hiện tượng ngạt khí (hypoxia), giúp người nuôi có đủ thời gian chuẩn bị phương án sục khí.
- **Độ mặn (Salinity):** Mức cải thiện xấp xỉ 26

2. Sự điều chỉnh thang đo đối với nhóm Vi sinh (Scale Calibration)

Kết quả ghi nhận sự gia tăng đột biến về giá trị RMSE của chỉ số Coliform (từ $\approx 1,070$ lên $\approx 10,429$ MPN) và NH₃. Đây không phải là sự suy giảm năng lực dự báo, mà là **sự hiệu chỉnh thang đo (Scale Calibration)**.

- Mô hình Baseline (Hong Kong) có xu hướng dự báo giá trị thấp do được huấn luyện trên môi trường nước sạch hơn.
- Mô hình Fine-tuned (Việt Nam) đã nhận diện được mức nền ô nhiễm thực tế cao hơn tại các vùng nuôi lồng bè ven bờ (nơi mật độ vi khuẩn thường xuyên đạt ngưỡng 10^4 MPN).

Việc RMSE tăng lên phản ánh đúng phương sai (Variance) lớn của dữ liệu thực tế. Trong ứng dụng cảnh báo, một mô hình phản ánh đúng mức độ ô nhiễm cao (dù sai số lớn) có giá trị thực tiễn cao hơn một mô hình luôn dự báo an toàn giả tạo.

3. Sự đánh đổi trong chỉ số Nhiệt độ (The Stability-Plasticity Trade-off)

Chỉ số Nhiệt độ ghi nhận sự gia tăng sai số từ $0.43^{\circ}C$ lên $0.74^{\circ}C$. Đây là minh chứng cho nguyên lý "Đánh đổi giữa Ổn định và Linh hoạt" trong học máy. Khi mô hình tập trung tài nguyên để tối ưu hóa

các hàm mục tiêu phức tạp như DO và pH, nó chấp nhận hy sinh một phần độ mượt mà (smoothness) trong dự báo nhiệt độ. Tuy nhiên, xét trên khía cạnh sinh học, sai số $\pm 0.75^{\circ}C$ vẫn nằm trong ngưỡng an toàn tuyệt đối (Vùng chịu nhiệt của Hàu và Cá giò dao động từ $15-32^{\circ}C$), do đó không ảnh hưởng đến giá trị sử dụng.

c. Kết luận mục

Tổng hợp lại, kết quả định lượng khẳng định chiến lược Fine-tuning đã thành công trong việc chuyển đổi mô hình từ trạng thái "Tổng quát hóa thấp" (High Bias) sang trạng thái "Thích nghi cao" (Low Bias) đối với các yếu tố môi trường cốt lõi. Mô hình sau tinh chỉnh đạt độ chính xác cấp độ phòng thí nghiệm đối với pH và DO, đủ điều kiện để triển khai ứng dụng thực tế.

4 Xây dựng bộ chỉ số phù hợp sinh học và bản đồ vùng nuôi

4.1 Công thức tính mức độ phù hợp sinh học (HSI)

4.1.1 Chỉ số phù hợp sinh cảnh (Habitat Suitability Index – HSI)

Chỉ số phù hợp sinh cảnh (Habitat Suitability Index – HSI) là một chỉ số tổng hợp được sử dụng rộng rãi trong các nghiên cứu sinh thái nhằm đánh giá mức độ phù hợp của điều kiện môi trường đối với sự sinh trưởng và phát triển của một loài sinh vật cụ thể. Trong lĩnh vực nuôi trồng thủy sản và quản lý môi trường nước, chỉ số HSI và các chỉ số tương tự đã được áp dụng trong nhiều báo cáo và nghiên cứu của các tổ chức quốc tế như Tổ chức Lương thực và Nông nghiệp Liên Hợp Quốc (Food and Agriculture Organization – FAO) và các chương trình đánh giá môi trường ven biển.

Trong nghiên cứu này, chỉ số HSI được sử dụng để đánh giá mức độ phù hợp của môi trường nước đối với hai đối tượng nuôi trồng thủy sản là hàu (oyster) và cá giò (cobia), dựa trên các yếu tố môi trường và kim loại nặng được dự báo.

4.1.2 Nguyên tắc xây dựng chỉ số HSI

Việc xây dựng chỉ số HSI trong nghiên cứu được thực hiện theo hướng tiếp cận dựa trên luật (rule-based), trong đó mỗi biến môi trường được ánh xạ thành một điểm phù hợp sinh học (suitability score) trong khoảng từ 0 đến 1. Giá trị 1 biểu thị điều kiện tối ưu cho loài, trong khi giá trị 0 biểu thị điều kiện hoàn toàn không phù hợp.

Đối với mỗi loài, một tập các ngưỡng sinh học đặc trưng được xác định, bao gồm:

- Khoảng giá trị tối ưu (*optimal range*) đối với các biến có giá trị thích hợp nằm trong một khoảng nhất định (ví dụ: nhiệt độ, pH, độ mặn).
- Ngưỡng tối đa cho phép đối với các biến mà nồng độ càng thấp càng tốt (ví dụ: NH_3 , H_2S , kim loại nặng).
- Ngưỡng tối thiểu yêu cầu đối với các biến mà giá trị càng cao càng có lợi (ví dụ: oxy hòa tan).

Công thức tính và các ngưỡng này được lựa chọn dựa trên triết lý trong các mô hình HSI do US Fish and Wildlife Service (USFWS) đề xuất từ thập niên 1980. (Tham khảo **Brown (1986)** – *Habitat Suitability Index Models and Instream Flow Suitability Curves*)

4.1.3 Hàm đánh giá mức độ phù hợp cho từng biến

Với mỗi biến môi trường x , điểm phù hợp sinh học $S(x)$ được tính toán theo các quy tắc sau:

- Biến có khoảng tối ưu ($x \in [L, H]$):

$$S(x) = \begin{cases} \frac{x}{L}, & x < L \\ 1, & L \leq x \leq H \\ \frac{2H-x}{H}, & x > H \end{cases}$$

- **Biến có ngưỡng tối đa** ($x \leq M$):

$$S(x) = \max\left(0, 1 - \frac{x}{M}\right)$$

- **Biến có ngưỡng tối thiểu** ($x \geq m$):

$$S(x) = \min\left(1, \frac{x}{m}\right)$$

Trong trường hợp giá trị của biến bị thiếu hoặc không hợp lệ, điểm phù hợp sinh học của biến đó được gán bằng 0 nhằm phản ánh mức độ không chắc chắn và tránh làm tăng giả tạo chỉ số HSI tổng thể.

4.1.4 Tính toán chỉ số HSI tổng hợp

Đối với mỗi bản ghi dự báo tại một trạm và một thời điểm, chỉ số HSI tổng hợp được tính bằng trung bình cộng của các điểm phù hợp sinh học của tất cả các biến được xem xét:

$$HSI = \frac{1}{N} \sum_{i=1}^N S_i$$

trong đó S_i là điểm phù hợp sinh học của biến thứ i , và N là số lượng biến môi trường và kim loại nặng được sử dụng trong quá trình đánh giá.

Cách tiếp cận này cho phép mỗi biến đóng góp một cách đồng đều vào chỉ số HSI, đồng thời giúp đơn giản hóa quá trình tổng hợp và diễn giải kết quả.

4.1.5 Phân loại mức độ phù hợp sinh cảnh

Dựa trên giá trị HSI thu được, mức độ phù hợp sinh cảnh được phân loại thành bốn mức:

- $HSI \geq 0.85$: Rất phù hợp
- $0.75 \leq HSI < 0.85$: Phù hợp
- $0.50 \leq HSI < 0.75$: Ít phù hợp
- $HSI < 0.50$: Không phù hợp

Ngưỡng phân loại HSI được lựa chọn theo hướng tham khảo các thực hành phổ biến trong các nghiên cứu sinh thái và báo cáo quản lý môi trường, đồng thời được điều chỉnh cho phù hợp với đặc thù dữ liệu và đối tượng nuôi trồng. Việc sử dụng bốn mức phân loại cho phép phản ánh rõ ràng sự khác biệt về mức độ phù hợp sinh cảnh, từ các khu vực có điều kiện môi trường tối ưu cho nuôi trồng đến các khu vực tiềm ẩn rủi ro sinh thái. Việc phân loại này giúp chuyển đổi các giá trị HSI liên tục thành các mức đánh giá trực quan, thuận tiện cho việc phân tích không gian, so sánh giữa các khu vực và hỗ trợ ra quyết định trong quản lý và quy hoạch vùng nuôi trồng thủy sản.

4.2 Xác định phạm vi áp dụng của kết quả dự đoán

4.2.1 Nguyên tắc xác định bán kính ảnh hưởng

Việc xác định bán kính ảnh hưởng dựa trên giả thiết rằng các trạm có vị trí địa lý gần nhau sẽ có điều kiện sinh thái tương đồng hơn so với các trạm ở xa. Mức độ tương đồng sinh thái được đo lường thông

qua chỉ số phù hợp sinh cảnh (HSI). Khi khoảng cách giữa hai trạm tăng lên, độ chênh lệch HSI giữa chúng có xu hướng tăng, phản ánh sự suy giảm tương đồng sinh thái theo không gian.

Đối với mỗi trạm trung tâm i tại một quý xác định, nghiên cứu xem xét tất cả các trạm còn lại j trong cùng quý và tính:

- Khoảng cách không gian d_{ij} giữa hai trạm, được tính từ tọa độ phẳng VN2000 theo công thức Euclid:

$$d_{ij} = \frac{\sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}}{1000}$$

trong đó x, y là tọa độ theo đơn vị mét và d_{ij} được quy đổi sang kilômét.

- Độ chênh lệch sinh thái giữa hai trạm:

$$\Delta HSI_{ij} = |HSI_i - HSI_j|$$

4.2.2 Phân tích suy giảm tương đồng sinh thái theo khoảng cách

Để đánh giá mối quan hệ giữa khoảng cách không gian và mức độ tương đồng sinh thái, nghiên cứu không tính trực tiếp độ chênh lệch HSI trung bình trên toàn bộ các cặp trạm, mà áp dụng phương pháp phân bin khoảng cách (distance binning). Cách tiếp cận này nhằm tránh việc trộn lẫn các cặp trạm ở những khoảng cách rất khác nhau, vốn có thể làm che khuất quy luật suy giảm tương đồng theo không gian.

Cụ thể, các cặp trạm (i, j) được phân nhóm theo các khoảng cách rời rạc (bins) với độ rộng cố định, trong nghiên cứu này là 1 km. Mỗi bin h_k đại diện cho một thang không gian xác định, bao gồm các cặp trạm có khoảng cách d_{ij} nằm trong khoảng:

$$h_k = [k\Delta h, (k+1)\Delta h), \quad \Delta h = 1 \text{ km.}$$

Với mỗi bin khoảng cách h_k , độ chênh lệch sinh thái trung bình được tính như sau:

$$\overline{\Delta HSI}(h_k) = \frac{1}{N(h_k)} \sum_{d_{ij} \in h_k} |HSI_i - HSI_j|,$$

trong đó $N(h_k)$ là số cặp trạm có khoảng cách thuộc bin h_k .

Việc phân bin khoảng cách cho phép so sánh các cặp trạm ở cùng một thang không gian, từ đó phản ánh rõ ràng xu hướng suy giảm tương đồng sinh thái theo khoảng cách. Các bin ở khoảng cách nhỏ thường có giá trị $\overline{\Delta HSI}$ thấp, cho thấy các trạm gần nhau có điều kiện sinh thái tương đồng và kết quả dự báo có thể được áp dụng trong phạm vi này. Ngược lại, khi khoảng cách tăng, $\overline{\Delta HSI}$ có xu hướng tăng dần, phản ánh sự khác biệt sinh thái ngày càng rõ rệt giữa các trạm ở xa nhau.

Do đó, phương pháp phân bin khoảng cách không chỉ giúp làm trơn dữ liệu và giảm ảnh hưởng của nhiễu cục bộ, mà còn cung cấp cơ sở định lượng để xác định phạm vi không gian mà tại đó kết quả dự báo vẫn còn đại diện cho khu vực xung quanh trạm quan trắc.

4.2.3 Ngưỡng xác định mất tương đồng sinh thái

Thay vì sử dụng một ngưỡng cố định cho mọi trường hợp, nghiên cứu áp dụng ngưỡng động dựa trên độ phân tán của HSI trong từng quý. Cụ thể, ngưỡng chênh lệch sinh thái được xác định là:

$$\Delta HSI_{\text{threshold}} = 0.6 \times \sigma_{\text{HSI}}$$

trong đó σ_{HSI} là độ lệch chuẩn của chỉ số HSI của tất cả các trạm trong cùng quý. Cách tiếp cận này cho phép ngưỡng thích nghi với mức độ biến thiên thực tế của dữ liệu, đặc biệt trong trường hợp HSI có phân phối hẹp và ít biến động.

Ngưỡng 0.6σ được chọn vì nó nằm trong vùng chuyển tiếp của phân bố ΔHSI , nơi đường cong phân phối chênh lệch bắt đầu lệch khỏi xu thế tuyến tính. Điều này cho phép phát hiện sự suy giảm tương đồng sinh thái sớm nhưng vẫn tránh bị ảnh hưởng bởi các ngoại lệ ở phần đuôi phân bố.

4.2.4 Xác định bán kính ảnh hưởng R

Trên cơ sở kết quả phân tích độ chênh lệch HSI trung bình theo các bin khoảng cách, bán kính ảnh hưởng không gian của trạm i tại một quý xác định được định nghĩa là phạm vi lớn nhất mà trong đó điều kiện sinh thái vẫn còn tương đồng với trạm trung tâm. Cụ thể, bán kính ảnh hưởng R_i được xác định là khoảng cách lớn nhất sao cho độ chênh lệch HSI trung bình trong tất cả các bin nhỏ hơn hoặc bằng khoảng cách đó vẫn chưa vượt quá ngưỡng chênh lệch sinh thái cho phép.

Gọi $\overline{\Delta HSI}(h_k)$ là độ chênh lệch HSI trung bình của bin khoảng cách h_k , và $\Delta HSI_{\text{threshold}}$ là ngưỡng chênh lệch sinh thái đã xác định, bán kính ảnh hưởng R_i được xác định theo công thức:

$$R_i = \max \{h_k \mid \overline{\Delta HSI}(h_j) < \Delta HSI_{\text{threshold}}, \forall h_j \leq h_k\}.$$

Theo định nghĩa này, các bin khoảng cách nhỏ hơn hoặc bằng R_i tương ứng với vùng mà các trạm xung quanh vẫn duy trì mức độ tương đồng sinh thái với trạm trung tâm, cho phép kết quả dự báo tại trạm i được xem là có thể áp dụng trong phạm vi đó. Khi khoảng cách vượt quá R_i , độ chênh lệch sinh thái trung bình tăng lên và vượt ngưỡng cho phép, cho thấy môi trường không còn đủ tương đồng để tiếp tục áp dụng kết quả dự báo.

Trong trường hợp không có bin khoảng cách nào vượt ngưỡng chênh lệch trong phạm vi khảo sát (tối đa 30 km), bán kính ảnh hưởng được gán bằng giá trị khoảng cách cực đại này. Trường hợp này phản ánh rằng, trong phạm vi nghiên cứu, điều kiện sinh thái được dự báo là tương đối đồng nhất theo không gian và kết quả dự báo tại trạm trung tâm có tính đại diện trên toàn vùng khảo sát.

Quy trình xác định bán kính ảnh hưởng được áp dụng độc lập cho từng trạm và từng quý, tạo thành tập hợp các bán kính $R_{i,t}$ cho mỗi trạm i tại thời điểm t . Cách tiếp cận này cho phép phản ánh đồng thời tính không đồng nhất theo không gian và sự biến động theo thời gian của điều kiện môi trường, đồng thời cung cấp cơ sở định lượng để biểu diễn phạm vi đại diện không gian của kết quả dự báo trên bản đồ.

4.2.5 Ví dụ minh họa xác định bán kính ảnh hưởng không gian

Để minh họa quy trình xác định bán kính ảnh hưởng R , xét một trạm quan trắc trung tâm i tại quý t với chỉ số phù hợp sinh cảnh dự báo là $HSI_i = 0.81$, tương ứng với mức *Phù hợp*.

Các trạm quan trắc lân cận j trong bán kính khảo sát tối đa 20 km được xem xét. Khoảng cách không gian giữa hai trạm được tính theo công thức Euclid trong hệ tọa độ VN2000:

$$d_{ij} = \frac{\sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}}{1000}$$

trong đó x, y được đo bằng mét và d_{ij} tính bằng km.

Bước 1: Chia khoảng cách theo các bin Các cặp trạm (i, j) được gom vào các khoảng cách rời rạc (bins) có độ rộng cố định 1 km, ví dụ: $[0, 1)$, $[1, 2)$, $[2, 3)$, ...

Bước 2: So sánh mức độ phù hợp sinh thái theo bin Trong mỗi bin khoảng cách, chỉ số HSI của các trạm lân cận được phân loại theo các mức sinh thái đã xác định trước (Rất phù hợp, Phù hợp, Ít phù hợp, Không phù hợp).

Nếu trong một bin tồn tại ít nhất một trạm có mức HSI khác với mức HSI của trạm trung tâm, bin đó được xem là ranh giới mà tại đó điều kiện sinh thái không còn tương đồng.


Bước 3: Xác định bán kính ảnh hưởng Giả sử kết quả thu được như sau:

- Trong các bin từ 0–1 km đến 5–6 km, tất cả các trạm đều có cùng mức HSI là *Phù hợp*.
- Tại bin 6–7 km, xuất hiện trạm có mức HSI là *Ít phù hợp*.

Khi đó, bán kính ảnh hưởng không gian của trạm i tại quý t được xác định là:

$$R_{i,t} = 6 \text{ km}$$

4.3 Thiết kế dashboard và bản đồ dự báo vùng nuôi trồng



Hình 3: Giao diện biểu diễn dữ liệu

4.3.1 Kiến trúc tổng thể của hệ thống Dashboard

Để chuyển đổi các kết quả dự báo từ mô hình học máy thành công cụ hỗ trợ quyết định thực tiễn cho người nuôi trồng thủy sản, nghiên cứu đã xây dựng một hệ thống Dashboard tương tác dựa trên nền

tăng web. Hệ thống được phát triển bằng framework Streamlit, một công cụ mã nguồn mở chuyên biệt cho việc xây dựng các ứng dụng khoa học dữ liệu và học máy với giao diện người dùng trực quan.

Kiến trúc của hệ thống được thiết kế theo mô hình ba tầng (Three-tier Architecture):

- **Tầng trình bày (Presentation Layer):** Giao diện web tương tác được render bởi Streamlit, cung cấp các thành phần điều khiển (widgets) để người dùng lựa chọn tham số dự báo và xem kết quả.
- **Tầng xử lý nghiệp vụ (Business Logic Layer):** Các module Python chuyên biệt thực hiện tính toán dự báo, tính toán HSI và xử lý dữ liệu địa lý.
- **Tầng dữ liệu (Data Layer):** Các file CSV chứa dữ liệu quan trắc, mô hình đã huấn luyện (file .pkl) và dữ liệu bán kính ảnh hưởng.

Ưu điểm của kiến trúc này nằm ở tính mô-đun hóa (Modularity) và khả năng mở rộng (Scalability). Mỗi thành phần có thể được cập nhật độc lập mà không ảnh hưởng đến toàn bộ hệ thống, đảm bảo tính bền vững trong quá trình bảo trì và nâng cấp.

4.3.2 Các thành phần giao diện người dùng

Hệ thống Dashboard được tổ chức thành các phần chức năng độc lập, mỗi phần phục vụ một mục đích cụ thể trong quy trình ra quyết định:

1. Phần cấu hình tham số dự báo (Forecast Parameters Configuration)

Đây là phần đầu tiên mà người dùng tương tác, cho phép thiết lập các tham số đầu vào cho quá trình dự báo:

- **Lựa chọn đối tượng nuôi trồng:** Người dùng có thể chọn giữa "Cá giò" (cobia) hoặc "Hàu" (oyster). Mỗi lựa chọn sẽ kích hoạt một bộ mô hình dự báo và ngưỡng HSI tương ứng, phản ánh sự khác biệt về yêu cầu sinh thái giữa hai loài.
- **Thiết lập thời gian dự báo:** Bao gồm năm bắt đầu (từ 2026 đến 2030), quý bắt đầu (1-4) và số lượng quý cần dự báo (1-20 quý). Các ràng buộc này đảm bảo tính hợp lệ của dữ liệu đầu vào và ngăn chặn các truy vấn không khả thi.

2. Phần bản đồ tương tác (Interactive Map Section)

Bản đồ địa lý là thành phần trung tâm của Dashboard, được xây dựng dựa trên thư viện Folium - một công cụ Python chuyên biệt để tạo bản đồ web tương tác. Bản đồ sử dụng nền ảnh vệ tinh (Satellite Imagery) từ dịch vụ Esri World Imagery, cung cấp hình ảnh độ phân giải cao giúp người dùng nhận diện chính xác vị trí các trạm quan trắc và vùng nuôi trồng.

Các thành phần được tích hợp trên bản đồ bao gồm:

- **Điểm đánh dấu trạm quan trắc (Station Markers):** Mỗi trạm được biểu diễn bằng một điểm tròn (CircleMarker) có màu sắc động phản ánh mức độ HSI. Hệ thống mã màu được thiết kế theo nguyên tắc trực quan:
 - Màu xanh lá cây (●): $HSI \geq 0.85$ (Rất phù hợp)
 - Màu vàng cam (●): $0.75 \leq HSI < 0.85$ (Phù hợp)
 - Màu cam (●): $0.50 \leq HSI < 0.75$ (Ít phù hợp)

– Màu đỏ (●): $HSI < 0.50$ (Không phù hợp)

- **Vùng ảnh hưởng không gian (Spatial Influence Zones):** Mỗi trạm được bao quanh bởi một vòng tròn màu xanh dương trong suốt, biểu thị bán kính ảnh hưởng R_i (tính bằng kilômét) đã được tính toán từ phương pháp phân tích suy giảm tương đồng sinh thái. Vùng này cho biết phạm vi không gian mà kết quả dự báo của trạm có thể được áp dụng một cách đáng tin cậy.
- **Thông tin popup và tooltip:** Khi người dùng di chuột (hover) hoặc click vào một điểm đánh dấu, một cửa sổ popup hiển thị thông tin chi tiết bao gồm: tên trạm, tọa độ địa lý (vĩ độ, kinh độ), giá trị HSI, mức đánh giá và bán kính áp dụng.

3. Phần tính toán HSI chi tiết (Detailed HSI Calculation)

Phần này cho phép người dùng thực hiện phân tích sâu cho một trạm quan trắc cụ thể. Hệ thống cung cấp:

- **Công cụ tìm kiếm trạm:** Thanh tìm kiếm cho phép người dùng nhập mã trạm hoặc tên trạm để nhanh chóng định vị trạm mong muốn.
- **Danh sách lựa chọn trạm:** Dropdown menu hiển thị danh sách tất cả các trạm quan trắc, được sắp xếp theo thứ tự số để dễ dàng tra cứu.
- **Nút kích hoạt tính toán:** Khi người dùng click vào nút "Tính HSI", hệ thống sẽ thực thi quy trình dự báo đầy đủ cho trạm đã chọn.

4.3.3 Cơ chế tính toán và hiển thị kết quả

a. Quy trình xử lý dữ liệu theo yêu cầu người dùng

Khi người dùng thiết lập các tham số và chọn trạm, hệ thống thực hiện một chuỗi các bước xử lý tuần tự:

Bước 1: Truy xuất tọa độ trạm Hệ thống tra cứu tọa độ VN-2000 (X_i, Y_i) của trạm đã chọn từ cơ sở dữ liệu. Tọa độ này được chuyển đổi sang hệ tọa độ địa lý WGS84 (vĩ độ, kinh độ) bằng hàm chuyển đổi tọa độ địa lý để hiển thị trên bản đồ.

Bước 2: Gọi mô hình dự báo Hàm `predict_for_station()` được gọi với các tham số:

$$\mathbf{Y}_{forecast} = M_{finetuned}(\mathbf{X}_{input}) \quad (12)$$

trong đó $\mathbf{X}_{input}$ là vector đặc trưng được xây dựng từ dữ liệu lịch sử của trạm (bao gồm các biến trễ Lag 1, Lag 4 và biến thời gian Quarter), và $\mathbf{Y}_{forecast}$ là vector dự báo chứa 11 chỉ số môi trường cho n quý tương lai.

Bước 3: Tính toán HSI Vector dự báo $\mathbf{Y}_{forecast}$ được đưa vào hàm `compute_hsi()` để tính toán chỉ số HSI cho từng quý. Hàm này áp dụng các công thức đánh giá mức độ phù hợp sinh học đã được trình bày trong phần trước, tạo ra một cột HSI và một cột HSI_Level (phân loại mức độ phù hợp) trong DataFrame kết quả.

Bước 4: Tích hợp thông tin bán kính ảnh hưởng Hệ thống tra cứu bán kính ảnh hưởng R_i tương ứng với trạm, quý và năm đã chọn từ file CSV chứa dữ liệu bán kính đã được tính toán trước. Thông tin này được gắn vào mỗi dòng dự báo để người dùng biết phạm vi áp dụng kết quả.

b. Hiển thị kết quả dưới dạng đa phương thức (Multi-modal Visualization)

Để tối ưu hóa trải nghiệm người dùng, kết quả được trình bày qua ba tab riêng biệt, mỗi tab phục vụ một mục đích phân tích khác nhau:

Tab 1: Biểu đồ HSI (HSI Trend Chart)

Biểu đồ đường (Line Chart) được xây dựng bằng thư viện Plotly, hiển thị xu hướng biến đổi HSI qua các quý dự báo. Biểu đồ được bổ sung ba đường ngưỡng (threshold lines) dạng nét đứt:

- Đường ngưỡng "Rất phù hợp" tại $HSI = 0.85$ (màu xanh lá)
- Đường ngưỡng "Phù hợp" tại $HSI = 0.75$ (màu cam)
- Đường ngưỡng "Ít phù hợp" tại $HSI = 0.50$ (màu đỏ)

Các đường ngưỡng này giúp người dùng nhanh chóng nhận diện các quý có điều kiện môi trường thuận lợi hoặc bất lợi cho nuôi trồng. Ngoài ra, biểu đồ hiển thị ba chỉ số thống kê quan trọng: HSI trung bình, HSI thấp nhất và HSI cao nhất trong chuỗi dự báo.

Tab 2: Biểu đồ các thông số môi trường (Environmental Parameters Visualization)

Tab này cung cấp cái nhìn chi tiết về từng chỉ số môi trường riêng lẻ. Người dùng có thể lựa chọn các thông số muốn xem thông qua hộp chọn đa lựa chọn (multiselect). Hệ thống tự động tạo một lưới biểu đồ con (subplot grid) với 2 cột, mỗi biểu đồ con hiển thị xu hướng biến đổi của một thông số theo thời gian.

Các thông số được hỗ trợ bao gồm: Nhiệt độ, Độ mặn, Oxy hòa tan (DO), pH, Độ đục (Turbidity), Chlorophyll-a, Amoni (NH_4^+), Nitrat (NO_3^-), và Phosphat (PO_4^{3-}). Dưới mỗi nhóm biểu đồ, một bảng thống kê hiển thị các chỉ số mô tả (trung bình, min, max, độ lệch chuẩn) cho các thông số đã chọn, giúp người dùng có cái nhìn tổng quan về phân phối giá trị.

Tab 3: Bảng dữ liệu chi tiết (Detailed Data Table)

Tab cuối cùng trình bày toàn bộ kết quả dự báo dưới dạng bảng dữ liệu có cấu trúc, bao gồm các cột: Thời gian (Quý/Năm), HSI, Đánh giá, và Bán kính áp dụng (km). Bảng được định dạng với các cấu hình cột (column configuration) để đảm bảo hiển thị số liệu chính xác (ví dụ: HSI hiển thị 3 chữ số thập phân, bán kính hiển thị 1 chữ số thập phân).

4.3.4 Tối ưu hóa hiệu năng và trải nghiệm người dùng

a. Cơ chế xử lý song song (Parallel Processing)

Một thách thức kỹ thuật quan trọng trong việc xây dựng Dashboard là thời gian tính toán. Khi người dùng yêu cầu hiển thị HSI cho tất cả các trạm trên bản đồ, hệ thống cần thực hiện hàng chục đến hàng trăm lần gọi mô hình dự báo. Nếu xử lý tuần tự (sequential processing), thời gian chờ có thể lên tới vài phút, gây trải nghiệm người dùng kém.

Để giải quyết vấn đề này, nghiên cứu áp dụng kỹ thuật xử lý song song đa luồng (Multi-threading) thông qua lớp `ThreadPoolExecutor` của Python. Cơ chế hoạt động như sau:

- **Phân chia tác vụ:** Danh sách các trạm cần tính toán được chia thành các nhóm nhỏ.
- **Thực thi song song:** Mỗi nhóm được gán cho một luồng xử lý (thread) độc lập. Tối đa 4 luồng được chạy đồng thời (`max_workers=4`) để tránh quá tải bộ nhớ và CPU.

- **Tổng hợp kết quả:** Sau khi tất cả các luồng hoàn thành, kết quả được gom lại (aggregate) thành một từ điển (dictionary) chứa HSI của tất cả các trạm.

Kỹ thuật này giúp giảm thời gian tính toán từ vài phút xuống còn vài chục giây, đảm bảo Dashboard phản hồi nhanh chóng và mượt mà.

b. Cơ chế lưu trữ tạm thời (Caching Mechanism)

Streamlit cung cấp decorator `@st.cache_data` cho phép lưu trữ kết quả của các hàm tính toán tốn kém.

Nghiên cứu áp dụng cơ chế này cho hai hàm quan trọng:

- **Hàm `load_data()`:** Đọc và xử lý dữ liệu quan trắc từ file CSV, bao gồm chuyển đổi tọa độ VN-2000 sang WGS84. Kết quả được cache để tránh phải thực hiện lại quá trình chuyển đổi tọa độ tốn thời gian mỗi khi người dùng tương tác với giao diện.
- **Hàm `load_radius_data()`:** Đọc dữ liệu bán kính ảnh hưởng từ file CSV. Dữ liệu này không thay đổi trong suốt phiên làm việc, do đó việc cache giúp tăng tốc độ truy xuất.

Cơ chế cache hoạt động dựa trên việc so sánh hash của các tham số đầu vào. Nếu tham số không thay đổi, hàm sẽ trả về kết quả đã lưu thay vì thực thi lại, tiết kiệm đáng kể thời gian và tài nguyên tính toán.

c. Tương tác động giữa bản đồ và giao diện (Dynamic Map-Interface Interaction)

Hệ thống được thiết kế để tạo ra sự tương tác mượt mà giữa bản đồ và các thành phần giao diện khác.

Khi người dùng click vào một điểm đánh dấu trên bản đồ:

1. Hệ thống xác định trạm gần nhất với vị trí click bằng cách tính khoảng cách Euclid giữa tọa độ click và tọa độ của tất cả các trạm.
2. Trạm được chọn được lưu vào session state (trạng thái phiên làm việc) của Streamlit.
3. Giao diện tự động cập nhật: Dropdown menu chọn trạm được điều chỉnh để hiển thị trạm vừa được chọn, và nếu người dùng đã bật tính toán HSI, kết quả sẽ được hiển thị ngay lập tức.

Cơ chế này tạo ra trải nghiệm người dùng liền mạch, cho phép người dùng khám phá dữ liệu một cách trực quan thông qua bản đồ thay vì phải nhập mã trạm thủ công.

4.3.5 Ý nghĩa thực tiễn và khả năng ứng dụng

Hệ thống Dashboard được thiết kế không chỉ là công cụ hiển thị kết quả, mà còn là một nền tảng hỗ trợ quyết định thực tiễn cho các bên liên quan trong ngành nuôi trồng thủy sản:

- **Đối với người nuôi trồng:** Dashboard cung cấp thông tin dự báo dễ hiểu và trực quan, giúp họ lập kế hoạch mùa vụ, chọn thời điểm thả giống tối ưu và chuẩn bị các biện pháp ứng phó khi điều kiện môi trường bất lợi.
- **Đối với cơ quan quản lý:** Hệ thống hỗ trợ công tác quy hoạch vùng nuôi trồng, xác định các khu vực có tiềm năng phát triển và các khu vực cần giám sát chặt chẽ.
- **Đối với nhà nghiên cứu:** Dashboard cung cấp giao diện để khám phá và phân tích dữ liệu, hỗ trợ các nghiên cứu tiếp theo về mối quan hệ giữa môi trường và nuôi trồng thủy sản.

Tóm lại, hệ thống Dashboard và bản đồ dự báo đóng vai trò là cầu nối quan trọng giữa các kết quả nghiên cứu khoa học và ứng dụng thực tiễn, góp phần nâng cao hiệu quả và tính bền vững của hoạt động nuôi trồng thủy sản tại vùng biển Quảng Ninh.

5 Kết luận

5.1 Kết quả thu được

Trong khuôn khổ dự án, nhóm đã xây dựng và triển khai thành công một quy trình phân tích và dự báo chất lượng môi trường nước ven biển nhằm phục vụ đánh giá mức độ phù hợp sinh cảnh (Habitat Suitability Index – HSI) cho nuôi trồng thủy sản, với hai đối tượng nghiên cứu chính là hàu và cá giò. Quy trình được thiết kế theo hướng tổng hợp, kết hợp giữa xử lý dữ liệu chuỗi thời gian, mô hình học máy và đánh giá sinh thái, từ đó hình thành một hệ thống phân tích tương đối hoàn chỉnh.

Về mặt dữ liệu, nhóm đã thu thập và xử lý dữ liệu quan trắc môi trường nước theo quý tại các trạm ven biển. Các bước tiền xử lý được thực hiện một cách hệ thống, bao gồm chuẩn hóa định dạng thời gian, làm sạch dữ liệu, xử lý các giá trị dưới ngưỡng phát hiện, nội suy và xử lý dữ liệu thiếu, giảm ảnh hưởng của các giá trị ngoại lai, cũng như xây dựng các đặc trưng độ trễ. Việc sử dụng các đặc trưng độ trễ (lag features) cho phép mô hình nắm bắt được xu hướng, tính chu kỳ và sự phụ thuộc theo thời gian của các yếu tố môi trường tại từng trạm quan trắc.

Trên cơ sở dữ liệu đã được xử lý, nhóm đã xây dựng và huấn luyện các mô hình học máy dựa trên thuật toán XGBoost để dự báo các biến môi trường theo quý. Các mô hình được chia thành hai nhóm chính: nhóm mô hình dự báo các kim loại nặng (CN, As, Cd, Pb, Cu, Hg, Zn, Total Cr) và nhóm mô hình dự báo các biến môi trường không phải kim loại (DO, pH, nhiệt độ, độ mặn, NH₃, BOD₅, TSS, v.v.). Kết quả đánh giá trên tập huấn luyện cho thấy các mô hình đạt sai số dự báo ở mức chấp nhận được, với giá trị RMSE trung bình của các biến môi trường chính dao động quanh ngưỡng từ khoảng 1.4 đến 1.6, tùy theo từng biến và từng đối tượng nuôi. Điều này cho thấy mô hình có khả năng học được các mối quan hệ phi tuyến giữa các yếu tố môi trường và phản ánh tương đối tốt xu hướng biến động theo thời gian. Phương pháp dự báo cuốn chiếu (rolling forecast) được áp dụng nhằm dự báo nhiều quý liên tiếp trong tương lai cho từng trạm quan trắc. Thông qua phương pháp này, kết quả dự báo của các quý trước được sử dụng làm đầu vào cho các bước dự báo tiếp theo, cho phép mô hình mô phỏng kịch bản biến động môi trường theo thời gian dài hơn và phản ánh tính liên tục của chuỗi thời gian.

Dựa trên kết quả dự báo các yếu tố môi trường, nhóm tiến hành tính toán chỉ số HSI cho từng đối tượng nuôi trồng. Mỗi biến môi trường được chuẩn hóa về thang giá trị từ 0 đến 1 dựa trên các ngưỡng sinh học đặc trưng cho hàu và cá giò, sau đó được tổng hợp để xác định mức độ phù hợp tổng thể của môi trường nuôi. Kết quả cho thấy chỉ số HSI có sự phân hóa rõ rệt theo không gian và thời gian, với các giá trị HSI trung bình dao động trong khoảng từ mức cận thuận lợi đến thuận lợi tại nhiều trạm ven biển trong một số giai đoạn, trong khi một số khu vực và thời điểm khác thể hiện mức HSI thấp, phản ánh điều kiện môi trường kém phù hợp cho nuôi trồng.

Ngoài ra, nhóm đã xây dựng một giao diện trực quan dưới dạng bản đồ vùng nuôi trồng, cho phép hiển thị kết quả dự báo các biến môi trường và chỉ số HSI theo từng trạm và từng quý trong tương lai. Giao diện này giúp người dùng dễ dàng theo dõi sự thay đổi của điều kiện môi trường, so sánh mức độ phù hợp sinh cảnh giữa các khu vực khác nhau, từ đó hỗ trợ quá trình đánh giá và ra quyết định trong quản lý nuôi trồng thủy sản.

5.2 Đánh giá kết quả và hướng phát triển

Tổng thể, các kết quả đạt được cho thấy quy trình phân tích và dự báo chất lượng môi trường nước được xây dựng trong dự án là khả thi và phù hợp với mục tiêu nghiên cứu. Các mô hình XGBoost thể hiện khả năng dự báo ổn định đối với các biến môi trường chính, với sai số RMSE ở mức chấp nhận được đối với dữ liệu chuỗi thời gian theo quý. Việc tích hợp kết quả dự báo vào chỉ số HSI cho phép chuyển đổi các kết quả học máy thành thông tin sinh thái có ý nghĩa thực tiễn, hỗ trợ đánh giá mức độ phù hợp môi trường cho nuôi trồng hàu và cá giò.

Tuy nhiên, dự án vẫn còn tồn tại một số hạn chế. Thứ nhất, độ chính xác của mô hình phụ thuộc lớn vào chất lượng và độ đầy đủ của dữ liệu quan trắc, trong khi một số biến môi trường chưa có dữ liệu thực tế đầy đủ và phải được bổ sung bằng dữ liệu tổng hợp. Thứ hai, phương pháp dự báo cuốn chiếu có thể dẫn đến hiện tượng tích lũy sai số khi dự báo trong nhiều bước thời gian liên tiếp, làm giảm độ tin cậy của kết quả trong dài hạn. Thứ ba, chỉ số HSI hiện tại được xây dựng dựa trên các ngưỡng sinh học cố định, chưa phản ánh đầy đủ khả năng thích nghi sinh thái theo từng khu vực và điều kiện môi trường cụ thể.

Trong các hướng phát triển tiếp theo, dự án có thể được mở rộng theo nhiều hướng. Một là, tích hợp thêm dữ liệu quan trắc mới, dữ liệu khí tượng – hải văn và các yếu tố tác động từ con người nhằm nâng cao độ chính xác của mô hình dự báo. Hai là, nghiên cứu và so sánh thêm các mô hình học sâu cho chuỗi thời gian, chẳng hạn như LSTM hoặc Transformer, để đánh giá khả năng cải thiện sai số RMSE và hạn chế tích lũy sai số trong dự báo dài hạn. Ba là, cải tiến phương pháp xây dựng chỉ số HSI theo hướng động, cho phép điều chỉnh ngưỡng sinh học theo không gian và thời gian. Cuối cùng, hệ thống trực quan có thể được phát triển thành một công cụ hỗ trợ ra quyết định hoàn chỉnh, phục vụ hiệu quả cho công tác quản lý và quy hoạch vùng nuôi trồng thủy sản trong thực tế.

6 Tài liệu tham khảo

References

- [1] Trung tâm Thông tin, dữ liệu biển và hải đảo quốc gia (NODC). <https://nodc.gov.vn/>
- [2] U.S. Fish and Wildlife Service (USFWS). *Habitat Suitability Index Models*. <https://www.fws.gov/>
- [3] Food and Agriculture Organization of the United Nations (FAO). *Site selection and carrying capacity for inland and coastal aquaculture*. FAO Fisheries and Aquaculture Technical Paper. <https://www.fao.org/fishery/>
- [4] Bộ Tài nguyên và Môi trường. *QCVN 10-MT:2015/BTNMT – Quy chuẩn kỹ thuật quốc gia về chất lượng nước biển*. Nhà xuất bản Tài nguyên Môi trường và Bản đồ Việt Nam, 2015.
- [5] National Oceanic and Atmospheric Administration (NOAA). *Habitat suitability and environmental indicators*. <https://www.noaa.gov/>
- [6] U.S. Environmental Protection Agency (EPA). *National Recommended Water Quality Criteria*. <https://www.epa.gov/wqc>
- [7] Roloff, G. J., Kernohan, B. J. (1999). Evaluating reliability of habitat suitability index models. *Wildlife Society Bulletin*, 27(4), 973–985.
- [8] Store, R., Jokimäki, J. (2003). A GIS-based multi-scale approach to habitat suitability modelling. *Ecological Modelling*, 169(1), 1–15.
- [9] Chen, T., Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- [10] Hyndman, R. J., Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts. <https://otexts.com/fpp3/>
- [11] Li, X., Sha, J., Wang, Z. (2020). Application of machine learning methods in water quality prediction: A review. *Water*, 12(6), 1–24.
- [12] Boyd, C. E. (2020). *Water Quality: An Introduction*. Springer, Cham.
- [13] Förstner, U., Wittmann, G. T. W. (2012). *Metal Pollution in the Aquatic Environment*. Springer-Verlag.
- [14] Kapetsky, J. M., Aguilar-Manjarrez, J., Jenness, J. (2013). A global assessment of potential for offshore mariculture development. *FAO Fisheries and Aquaculture Technical Paper*.