

1 Xử lý dữ liệu

Các bộ dữ liệu đã được tổng hợp và xử lý lại để phục vụ nghiên cứu và phát triển mô hình. Các bộ dữ liệu và mã nguồn xử lý được lưu trong link Drive dataset

https://drive.google.com/drive/folders/1OqbQMRTT_AFXQW8vSDadR0sTbTDIwyMp?usp=sharing.

1.1 Tổng hợp bộ dữ liệu CALCOFI

`cast.csv` Là bảng metadata cho mỗi “cast” (chuyến thả CTD / lấy mẫu) – mỗi hàng tương ứng một lần khảo sát tại một trạm, thời điểm và độ sâu cụ thể. `bottle.csv` Là bảng mẫu nước/chai lấy từ mỗi cast: mỗi hàng tương ứng một “chai” (bottle) hoặc một độ sâu tại một cast.

→ Tổng hợp thành file dữ liệu `calcofi_bottle_and_cast` biểu diễn chất lượng nước theo toạ độ và thời gian.

1.2 Tổng hợp dữ liệu từ HK Dataset

Chức năng chính

- **Đọc và chuẩn hóa dữ liệu thô:** Hàm `load_hk_water()` nạp các tệp CSV có tên dạng `marine_water_quality_*.csv`, chuẩn hóa tên cột (chữ thường, thay khoảng trắng bằng dấu gạch dưới), và xử lý giá trị giới hạn phát hiện (LOD) thông qua hàm `parse_lod()` — các giá trị dạng `<x` được thay thế bằng $x/2$.
- **Tổng hợp theo quý:** Hàm `aggregate_quarter()` lọc dữ liệu theo tầng nước (*depth*), tính trung bình tháng rồi trung bình quý theo từng trạm quan trắc (*station*).
- **Chuẩn hóa lược đồ (schema):** Hàm `standardize_schema()` ánh xạ các tên cột HK sang 21 biến chuẩn (theo bảng `COLUMN_MAP`), gồm: DO, Temperature, pH, Salinity, NH_3 , PO_4 , BOD_5 , TSS, Coliform, cùng các chỉ số kim loại nặng và hóa học khác.
- **Sinh dữ liệu tổng hợp (synthetic):** Bốn hàm bổ sung sinh các biến không có trong bộ dữ liệu HK gốc:
 - `add_synthetic_h2s()`: H_2S theo phân phối log-normal, giá trị nằm trong khoảng $[0.0005, 0.06]$ mg/L.
 - `add_synthetic_alkalinity()`: Độ kiềm theo phân phối chuẩn bị chặn (truncated normal), trung bình 120 mg/L.
 - `add_synthetic_transparency()`: Độ trong (Secchi disk) theo log-normal, trung bình 35 cm.
 - `add_synthetic_cod()`: COD theo log-normal lệch phải, trong khoảng $[8, 220]$ mg/L.

Đầu ra

Khi chạy trực tiếp (`__main__`), tệp xuất hai tệp CSV vào thư mục `prj/data/hk_water_quality/`:


- `hk_cobia_quarterly_21vars.csv` — dữ liệu tầng giữa (middle), dùng cho mô hình nuôi cá giò.
- `hk_oyster_quarterly_21vars.csv` — dữ liệu tầng mặt (surface), dùng cho mô hình nuôi hào.

Mỗi tệp chứa 21 biến chất lượng nước được tổng hợp theo quý và trạm quan trắc, sẵn sàng cho bước phân tích và mô hình hóa tiếp theo.

1.3 Tổng hợp dữ liệu các trạm quan trắc Quảng Ninh

Chuyển bảng từ file excel Tong hop NB.2021-2025.IN.xlsx thành file *qn_nv_clean_ready.csv* sẵn sàng làm đầu vào cho mô hình học máy. Ngoài ra file *toa_do_qn.csv* tổng hợp tọa độ của các trạm quan trắc.

2 Mô hình đề xuất



2.1 Áp dụng cho dữ liệu CALCOFI

Tệp *cnn-lstm.py* xây dựng một mô hình lai (*hybrid model*) kết hợp mạng LSTM và thuật toán XGBoost để dự đoán nồng độ oxy hòa tan trong nước biển (biến mục tiêu *O2m1_L*), sử dụng bộ dữ liệu CalCOFI (*bottle_and_cast.csv*).

Kỹ thuật đặc trưng (Feature Engineering)

- **Đặc trưng thời gian tuần hoàn:** Mã hóa tháng và ngày trong năm theo dạng $(\sin \theta, \cos \theta)$ nhằm biểu diễn tính chu kỳ mùa vụ:

$$x_{\text{month_sin}} = \sin\left(\frac{2\pi \cdot m}{12}\right), \quad x_{\text{month_cos}} = \cos\left(\frac{2\pi \cdot m}{12}\right)$$

- **Đặc trưng không gian:** Tọa độ vĩ độ và kinh độ được chuyển sang $(\sin, \cos)$ của góc radian để tránh phi liên tục tại ± 180 .
- **Đặc trưng vật lý tương tác:** Tích chéo giữa nhiệt độ, độ mặn và độ sâu (*temp_salinity*, *temp_depth*, *salinity_depth*) cùng chỉ số mật độ xấp xỉ:

$$\rho_{\text{proxy}} = S - 0.2 \cdot T$$

- **Đặc trưng trễ (lag):** Ba giá trị O_2 liền trước (*O2_lag1*, *O2_lag2*, *O2_lag3*).

Kiến trúc mô hình lai LSTM + XGBoost

Mô hình gồm hai giai đoạn kết hợp:

- Giai đoạn LSTM (trích xuất đặc trưng chuỗi thời gian):** Chuỗi đầu vào có độ dài $T = 12$ bước thời gian và 18 đặc trưng được xử lý qua hai lớp LSTM tầng chồng (64 và 32 đơn vị), sau đó ánh xạ xuống không gian nhúng 16 chiều qua lớp Dense với hàm kích hoạt ReLU. Mô hình LSTM được tối ưu bằng Adam với hàm mất mát MSE trong 20 epoch.
- Giai đoạn XGBoost (hồi quy cuối):** Vector đặc trưng cuối cùng được ghép nối:

$$\mathbf{x}_{\text{final}} = [\mathbf{X}_{\text{flat}} \parallel \mathbf{e}_{\text{LSTM}}]$$

trong đó $\mathbf{X}_{\text{flat}}$ là chuỗi đầu vào duỗi phẳng và $\mathbf{e}_{\text{LSTM}}$ là vector nhúng 16 chiều từ LSTM. **XGBRegressor** (1000 cây, learning rate 0.05, max_depth 5) được huấn luyện trên đặc trưng ghép này để đưa ra dự đoán cuối.

Phân chia dữ liệu và Đánh giá

Dữ liệu được phân chia theo thứ tự thời gian: 80% huấn luyện, 20% kiểm tra. Tất cả đặc trưng và biến mục tiêu được chuẩn hóa về $[0, 1]$ bằng **MinMaxScaler** trước khi đưa vào mô hình, và được khôi phục về đơn vị gốc khi tính chỉ số đánh giá. Các chỉ số sử dụng:

- MAE (Mean Absolute Error)
- RMSE (Root Mean Squared Error)
- R^2 (Hệ số xác định)

Bảng 1: So sánh hiệu năng giữa mô hình XGBoost và XGBoost-LSTM Hybrid

Chỉ số	XGBoost	XGBoost-LSTM Hybrid
MAE	0.986	1.013
RMSE	1.504	1.478
R^2	0.438	0.440

2.2 Áp dụng cho dữ liệu HK Dataset

Tập `test_hk.py` thực hiện thử nghiệm so sánh hiệu năng giữa mô hình hồi quy truyền thống và mô hình lai sử dụng mạng học sâu (*Deep Learning*) để dự báo đa mục tiêu 12 chỉ số chất lượng nước tại Hong Kong.

Các thành phần chính

- **Dữ liệu đầu vào:** Sử dụng tệp chuẩn hóa `hk_cobia_quarterly_21vars.csv`. Dữ liệu được làm sạch bằng cách nội suy (*interpolation*) và điền các giá trị thiếu còn lại bằng trung vị (*median*) theo từng trạm.

- **Mô hình cũ (Old Model - Baseline):** Sử dụng phương pháp trễ (lag-1, lag-4) cho tất cả các biến đặc trưng. Sau đó, một mô hình `XGBRegressor` được bọc trong `MultiOutputRegressor` để dự báo đồng thời các chỉ số ở thời điểm hiện tại dựa trên các giá trị trễ và thông tin quý.
- **Mô hình mới (New Model - Hybrid LSTM-XGB):** Cải tiến quy trình bằng cách kết hợp học chuỗi và hồi quy gradient boosting:
 - **LSTM Encoder:** Một mạng LSTM (cấu trúc PyTorch) được huấn luyện để nén chuỗi dữ liệu lịch sử (độ dài 4 quý) thành một vector nhúng (*embedding*) 32 chiều đại diện cho đặc trưng động lực học của trạm.
 - **XGBoost Decoder:** Vector nhúng này được ghép nối với thông tin quý (`embedding||quarter`) để làm đầu vào cho mô hình `XGBRegressor` cuối cùng.

Quy trình thực thi

1. **Chuẩn bị dữ liệu:** Hàm `prepare_lag()` tạo ma trận đặc trưng cho mô hình cũ, trong khi `prepare_seq()` tạo các khối tensor chuỗi ($N, seq_len, features$) cho mô hình LSTM.
2. **Huấn luyện:**
 - Mô hình cũ được huấn luyện trực tiếp trên toàn bộ tập dữ liệu.
 - Mô hình mới huấn luyện LSTM trước (tự mã hóa để trích xuất đặc trưng), sau đó dùng đặc trưng đó để huấn luyện XGBoost.
3. **Đánh giá:** Tính toán sai số RMSE (*Root Mean Squared Error*) cho từng biến mục tiêu và tính trung bình chung (**Mean RMSE**) để so sánh độ chính xác giữa hai cách tiếp cận.

Kết quả đầu ra

Chương trình in ra bảng so sánh chi tiết RMSE của mô hình *old* và *new* cho từng biến (DO, pH, NH₃, ...), giúp đánh giá ưu thế của việc sử dụng mạng LSTM trong việc trích xuất đặc trưng chuỗi thời gian so với các biến trễ thủ công.

Nhận xét chung Từ các kết quả thực nghiệm có thể nhận thấy rằng các mô hình lai sử dụng bộ mã hóa chuỗi thời gian, chẳng hạn như mô hình kết hợp LSTM và XGBoost, không cho kết quả vượt trội so với mô hình XGBoost thuần. Trong phần lớn các thí nghiệm, XGBoost đơn lẻ đạt giá trị RMSE và MAE thấp hơn một chút so với các kiến trúc kết hợp.

Nguyên nhân có thể xuất phát từ đặc điểm của bộ dữ liệu chất lượng nước HK. Mặc dù bài toán được xây dựng dưới dạng dự đoán chuỗi thời gian đa biến, nhưng số lượng bản ghi theo thời gian tại mỗi trạm quan trắc tương đối ít. Sau khi tạo các đặc trưng trễ (lag features), chiều dài chuỗi thời gian cho mỗi mẫu trở nên ngắn, khiến cho mô hình LSTM khó học được các phụ thuộc dài hạn một cách hiệu quả.

Trong khi đó, các mô hình dựa trên cây quyết định tăng cường như XGBoost thường hoạt động rất tốt trên dữ liệu dạng bảng với số lượng mẫu không lớn và số chiều đặc trưng vừa phải. Trong trường hợp này, việc bổ sung thêm tầng LSTM làm tăng độ phức tạp của mô hình nhưng không mang lại nhiều thông tin thời gian hữu ích, thậm chí có thể làm giảm nhẹ độ chính xác do tăng phương sai của mô hình.

Do đó, kết quả thực nghiệm cho thấy với những bộ dữ liệu có số quan sát theo thời gian hạn chế tại mỗi

Bảng 2: Kết quả sai số RMSE chi tiết cho từng biến số (Hong Kong)

Variable	XGBoost	LSTM+XGBoost
DO	0.48	0.52
Temperature	0.65	0.71
pH	0.08	0.09
Salinity	0.60	0.68
NH ₃	0.0027	0.0032
PO ₄	0.0054	0.0061
BOD5	0.24	0.29
COD	29.8	34.5
TSS	1.72	2.10
Coliform	3150	4200
Alkalinity	23.4	26.8
Transparency	7.2	8.6
Mean RMSE	268.05	357.28

trạm, các phương pháp boosting truyền thống như XGBoost vẫn là lựa chọn phù hợp và có tính cạnh tranh cao so với các mô hình học sâu kết hợp.